Створення систем штучного інтелекту та машинне навчання

Лекція #7

#unsupervised learning, PCA, k-means

д.т.н., професор Прохоров О.В.

Unsupervised Learning

Йдеться про вивчення цікавих/корисних структур у даних (без вчителя)

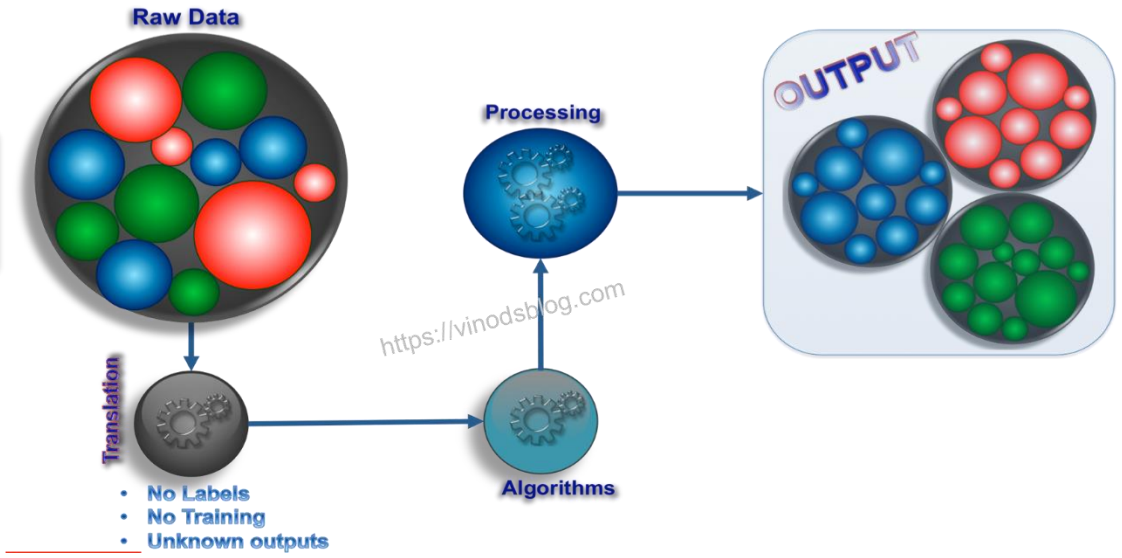

Тут ми маємо набір даних без міток. Наша мета — дізнатися щось цікаве про структуру даних:
• Кластери приховані в наборі даних
• Викиди: особливо незвичні та/або цікаві точки даних
• Корисний сигнал, прихований у шумі, наприклад, людська мова по гучному телефону

Неконтрольоване навчання має багато застосувань:

- системи рекомендацій: пропозиція фільмів на Netflix.
- виявлення аномалій: визначення заводських компонентів, які, ймовірно, незабаром вийдуть з ладу.
- усунення шуму сигналу: виділення людської мови із шумового запису.

Зменшення розмірності даних

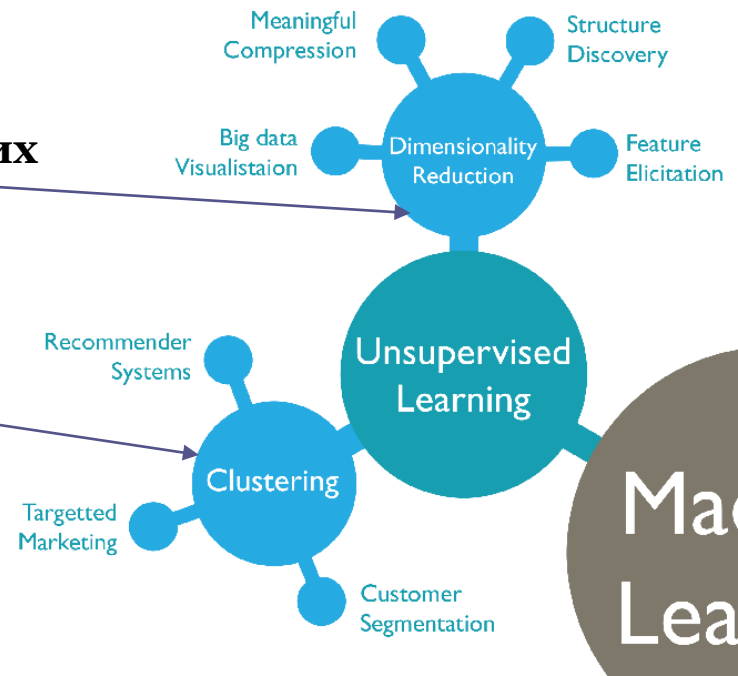

Кластеризація: групування схожих вхідних даних разом (і різнорідних, віддалених один від одного)

Кластерізація

- Дано: N немаркованих прикладів $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_N$; бажана кількість кластерів K
- Ціль: згрупувати приклади в K «однорідних» кластерів

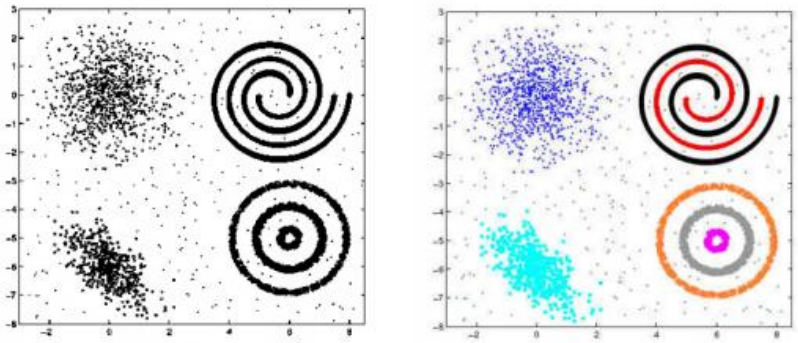

(a) Input data (b) Desired clustering

У деяких випадках ми можемо не знати правильну кількість кластерів у даних і можемо захотіти дізнатися про це

- Грубо кажучи, це класифікація без макерів істинності
- Хороша кластеризація – це така, яка досягає
  - високої подібності усередині кластера
  - низької міжкластерної подібності

Подібність може бути суб'єктивною

- Кластеризація розглядає лише схожість входів, оскільки мітки не надаються
- Без міток схожість важко визначити

- Таким чином, використання правильної відстані/подібності є дуже важливим у кластеризації
- У певному сенсі це пов’язано із запитанням: «Групування на основі чого»?

Кластерізація: деякі приклади

- Кластеризація документів/зображень/веб-сторінок

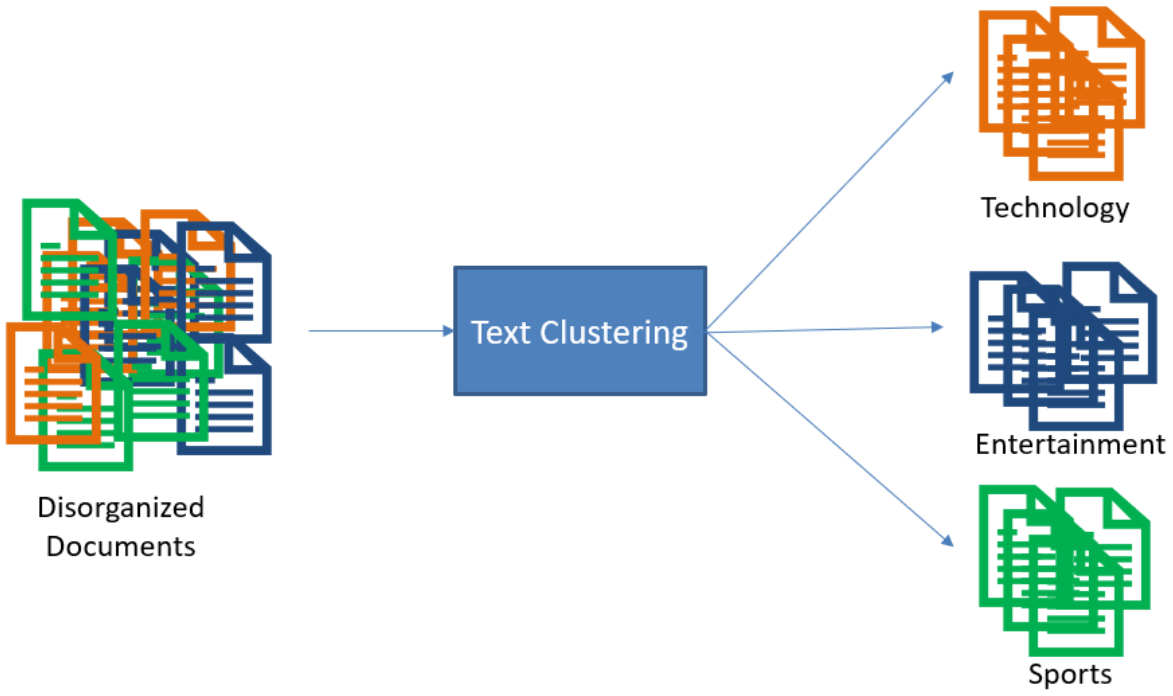

- Маючи набір текстових документів, ми хочемо впорядкувати їх відповідно до схожості вмісту, щоб створити ієрархію тем
- у зв’язку з постійним зростанням кількості онлайн-документів важливе значення має кластеризація в мережі Інтернет

Кластерізація: деякі приклади

- Сегментація клієнтів, ринку тощо

- сегментація клієнтів відповідно до їх схожості
- далі можливо робити цільовий маркетинг
- тощо

Кластерізація: деякі приклади

- Кластеризація та візуалізація вузлів (людей) у (соціальних) мережах/графах

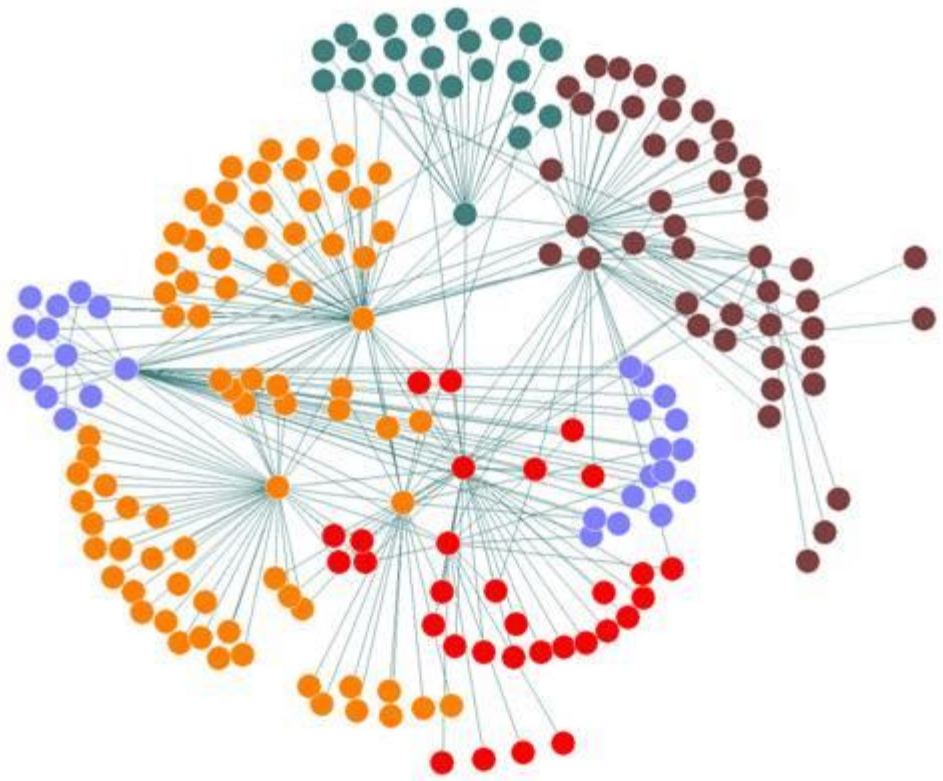

- соціометричні дослідження в соціальних мережах
- виділення спільнот у соціальних графах
- оптимізація потоків вхідної та вихідної інформації, вплив інфлуенсерів
- виявлення недійсних акаунтів та профілів у соціальних мережах, тих, що виступають у ролі спамів для подальшого блокування

Кластерізація: деякі приклади

- Кластеризація та візуалізація вузлів (людей) у (соціальних) мережах/графах

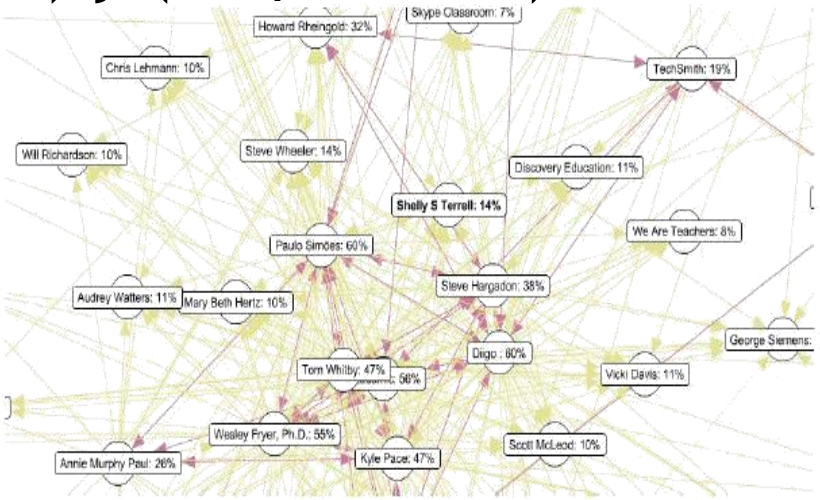

Методи виділення спільнот у соціальних графах активно досліджуються останнім часом, і візуалізація графа всього лише один із практичних аспектів цього завдання

Автоматично визначені спільноти найближчих контактів користувачів у соціальній мережі можуть бути використані для оптимізації потоків вхідної та вихідної інформації, або можуть бути задіяні для виявлення недійсних акаунтів або профілів у соціальних мережах, які виступають у ролі спамів для блокування та заспамлення реальних профілів-акаунтів

Таким чином, аналіз профілів учасників соціальних мереж є перспективним напрямом досліджень, що вимагає поєднання методів мережевого аналізу, теорії графів та штучного інтелекту

Результати можуть бути корисними для вирішення багатьох завдань, наприклад, для освітньої спільноти. Так, куратор може виділити неформального лідера у студентській групі, простежити, як змінюватиметься його роль протягом семестру. Виходячи з аналізу динаміки змін у структурі мережі студентів, можна формувати підгрупи для виконання різних освітніх чи наукових проектів. Для керівництва важливим є моніторинг змін, що відбуваються в робочому колективі з часом тощо

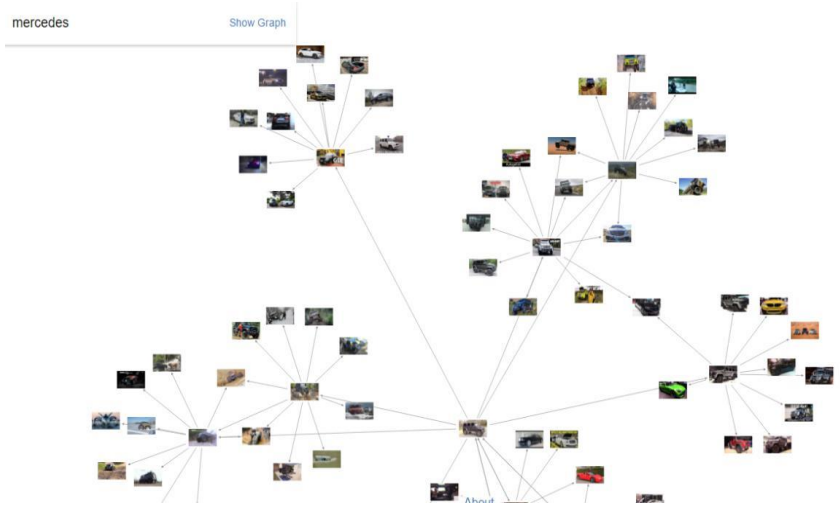

Кластерізація: деякі приклади

- Кластеризація результатів веб-пошуку

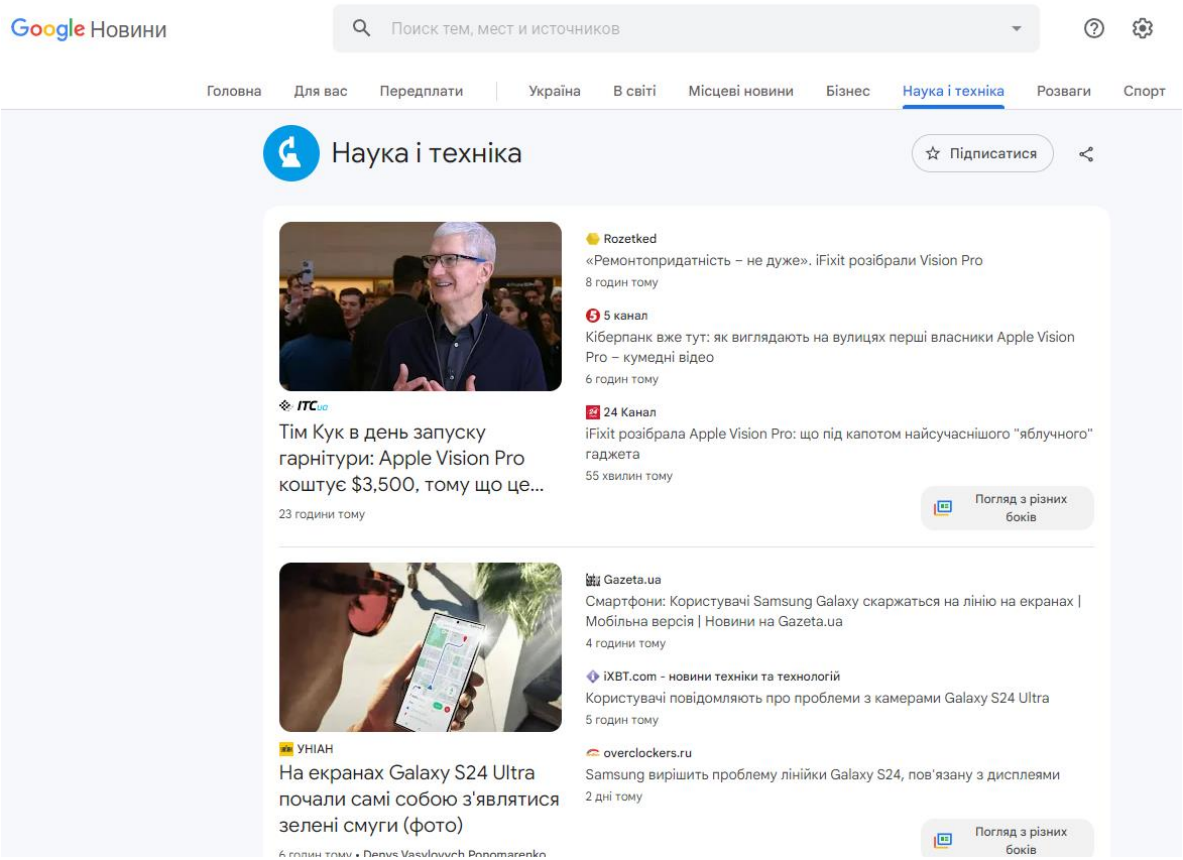

- Кластеризація результатів веб-пошуку спрямована на полегшення пошуку інформації в Інтернеті
- Замість того, щоб результати запиту представлялися як плоский список, вони групуються на основі своєї подібності та згодом показуються користувачам у списку кластерів
- Агрегація новин

Кластерізація: деякі приклади

- Сегментація зображень

- Сегментація зображення — це важливий етап комп’ютерного зору, на якому із зображення витягується корисна інформація, яка може варіюватися від пошуку об’єктів до виявлення аномалій у медичному зображенні
- Оскільки пікселі зображення, як правило, не позначені, для них зазвичай використовується підхід до кластеризації

Кластерізація: деякі приклади

- Відмінний приклад кластеризації - маркери на картах в Інтернеті. Коли ви шукаєте всі крафтові бари у Львоі, машині доводиться групувати їх в кружечки з циферками, інакше браузер зависне в потугах намалювати мільйон маркерів

- Більш складні приклади кластеризації можна згадати в додатках iPhoto або Google Photos, які знаходять особи людей на фотографіях і групують їх у альбоми. Додаток не знає як звуть ваших друзів, але може відрізнити їх за характерними рисами обличчя. Типова кластеризація. Правда для початку їм доводиться знайти ці самі «характерні риси», а це вже тільки з учителем

Типи кластеризації

- Плоска або часткова кластеризація
  - Кластери незалежні один від одного

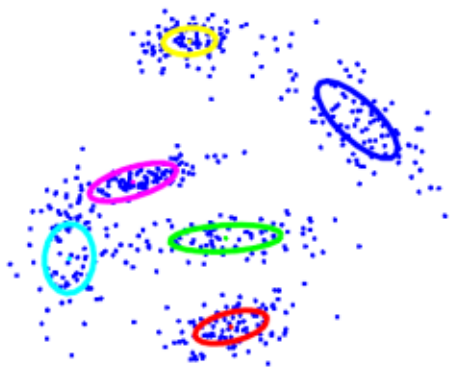

В ієрархічній кластеризації ми можемо подивитися на кластеризацію для будь-якої заданої кількості кластерів, «вирізавши дендрограму на відповідному рівні (тому K не потрібно вказувати)

- Ієрархічна кластеризація
  - Кластери можна візуалізувати за допомогою деревовидної структури (дендрограми)

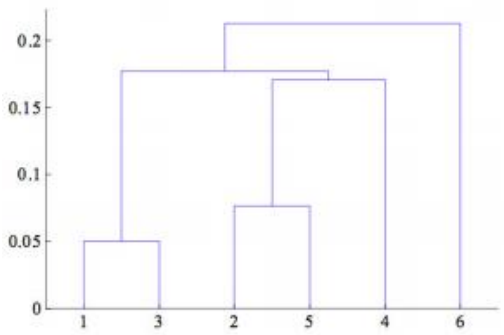

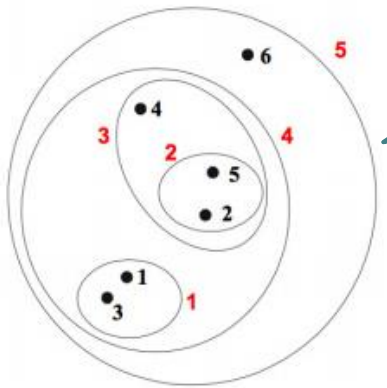

Ієрархічна кластеризація дає нам кластеризацію на кількох рівнях деталізації

Методи кластеризації

Існує багато методів кластерізації:

- k-середних (k-means)
- Алгоритм EM
- Нейронні мережі Кохонена: самоорганізуючі карти
- Аналіз головних компонентів (PCA)

K-means

Self-Organizing Maps

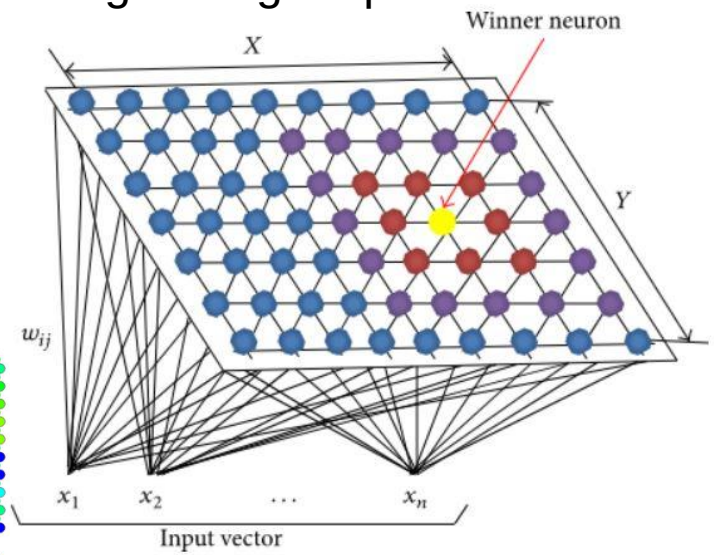

PCA

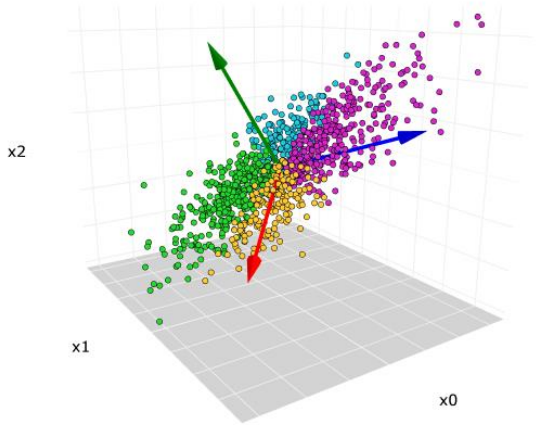

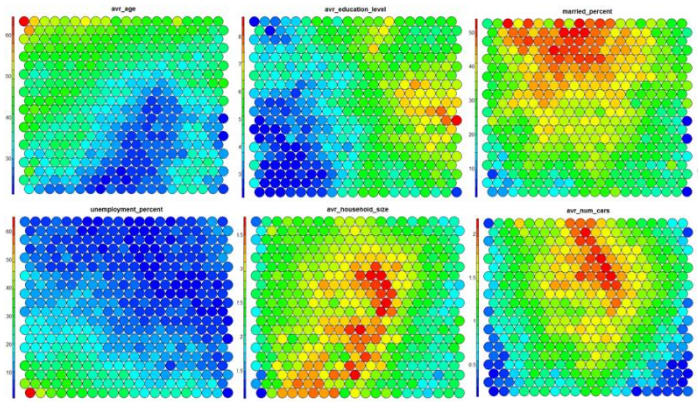


```
from sklearn_som.som import SOM
```

K-Means

- Припускає, що приклади є дійсними векторами
- Кластери на основі центроїдів (він же центр ваги або середнє) точок у кластері, *c*:

$$\boxed{\mu_k = \text{mean}(\mathcal{C}_k) = \frac{1}{|\mathcal{C}_k|} \sum_{n \in \mathcal{C}_k} \mathbf{x}_n}$$

- Перепризначення екземплярів кластерам ґрунтується на відстані до поточних центроїдів кластера
  - (або це можна еквівалентно сформулювати в термінах подібності)

K-Means

- **Вхідні дані:** N прикладів без міток $\boldsymbol{x}_1, \boldsymbol{x}_2, \dots, \boldsymbol{x}_N$; $\boldsymbol{x}_n \in \mathbb{R}^D$; бажана кількість кластерів K
- **Бажаний результат:** кластерне призначення цих N прикладів і K кластерних середних
- **Ініціалізація:** кластер K означає позначення $\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_K$; з кожним $\boldsymbol{\mu}_k \in \mathbb{R}^D$
  - Зазвичай ініціалізується випадковим чином, але хороша ініціалізація має вирішальне значення; існує багато розумніших евристик ініціалізації (наприклад, K-means++)

K-Means

Ітерації

- (повторення) призначити кожен вхід x_n найближчому центру кластера (на основі найменшої евклідової відстані)

$$\boxed{\mathcal{C}_k = \{n : \quad k = \arg\min_k ||\mathbf{x}_n - \boldsymbol{\mu}_k||^2\}}$$

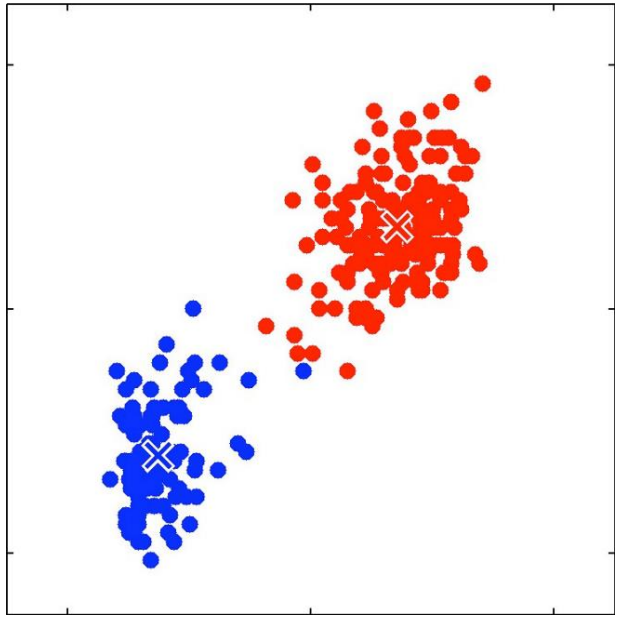

- Оновити центроід кластера

$$\boxed{\mu_k = \text{mean}(\mathcal{C}_k) = \frac{1}{|\mathcal{C}_k|} \sum_{n \in \mathcal{C}_k} \mathbf{x}_n}$$

- Повторювати, поки не зійдуться (виконаний критерій зупинки)
  - Деякі способи оголосити це між двома послідовними ітераціями:
    - фіксована кількість ітерацій
    - кластер починає не змінюватися (різниця між старим та новим центроїдами постійна)
    - призначення кластерів не змінюються
    - «втрати» кластеризації не сильно змінюються

K-Means

- Чому алгоритм K-середніх коли-небудь повинен досягати фіксованої точки?
  - тобто стан, у якому кластери не змінюються
- K-середні – це окремий випадок загальної процедури, відомої як алгоритм максимізації очікування *Expectation Maximization* (EM)
  - відомо, що EM сходиться
  - кількість ітерацій може бути великою.
    - але на практиці зазвичай ні

K-Means: вибір K

- Один із способів вибрати K для алгоритму K-середніх — це спробувати різні значення K, побудувати графік цілі K-середніх проти K та подивитися на «локтєву точку» (elbow-point)

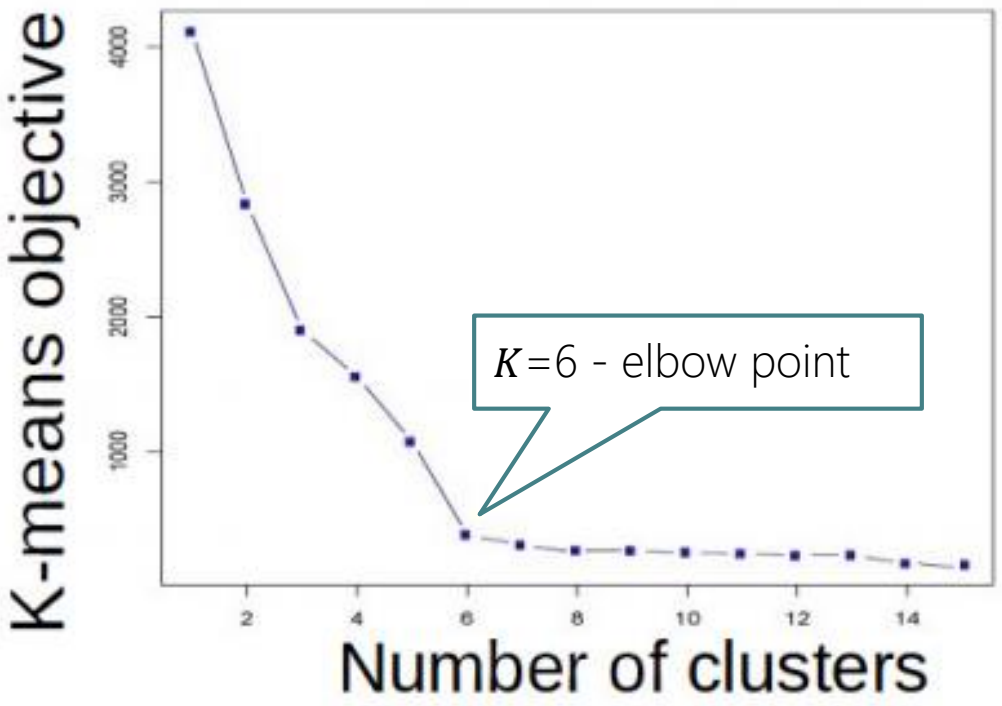

K-Means: приклад

1. Виберіть кількість кластерів *K*
2. Довільно ініціалізуйте *K* центроїди кластера
3. Призначте кожному екземпляру найближчий центроїд
4. Переоцініть центроїд кожного кластера
5. Повторюйте 3 і 4, поки не буде жодних покращень

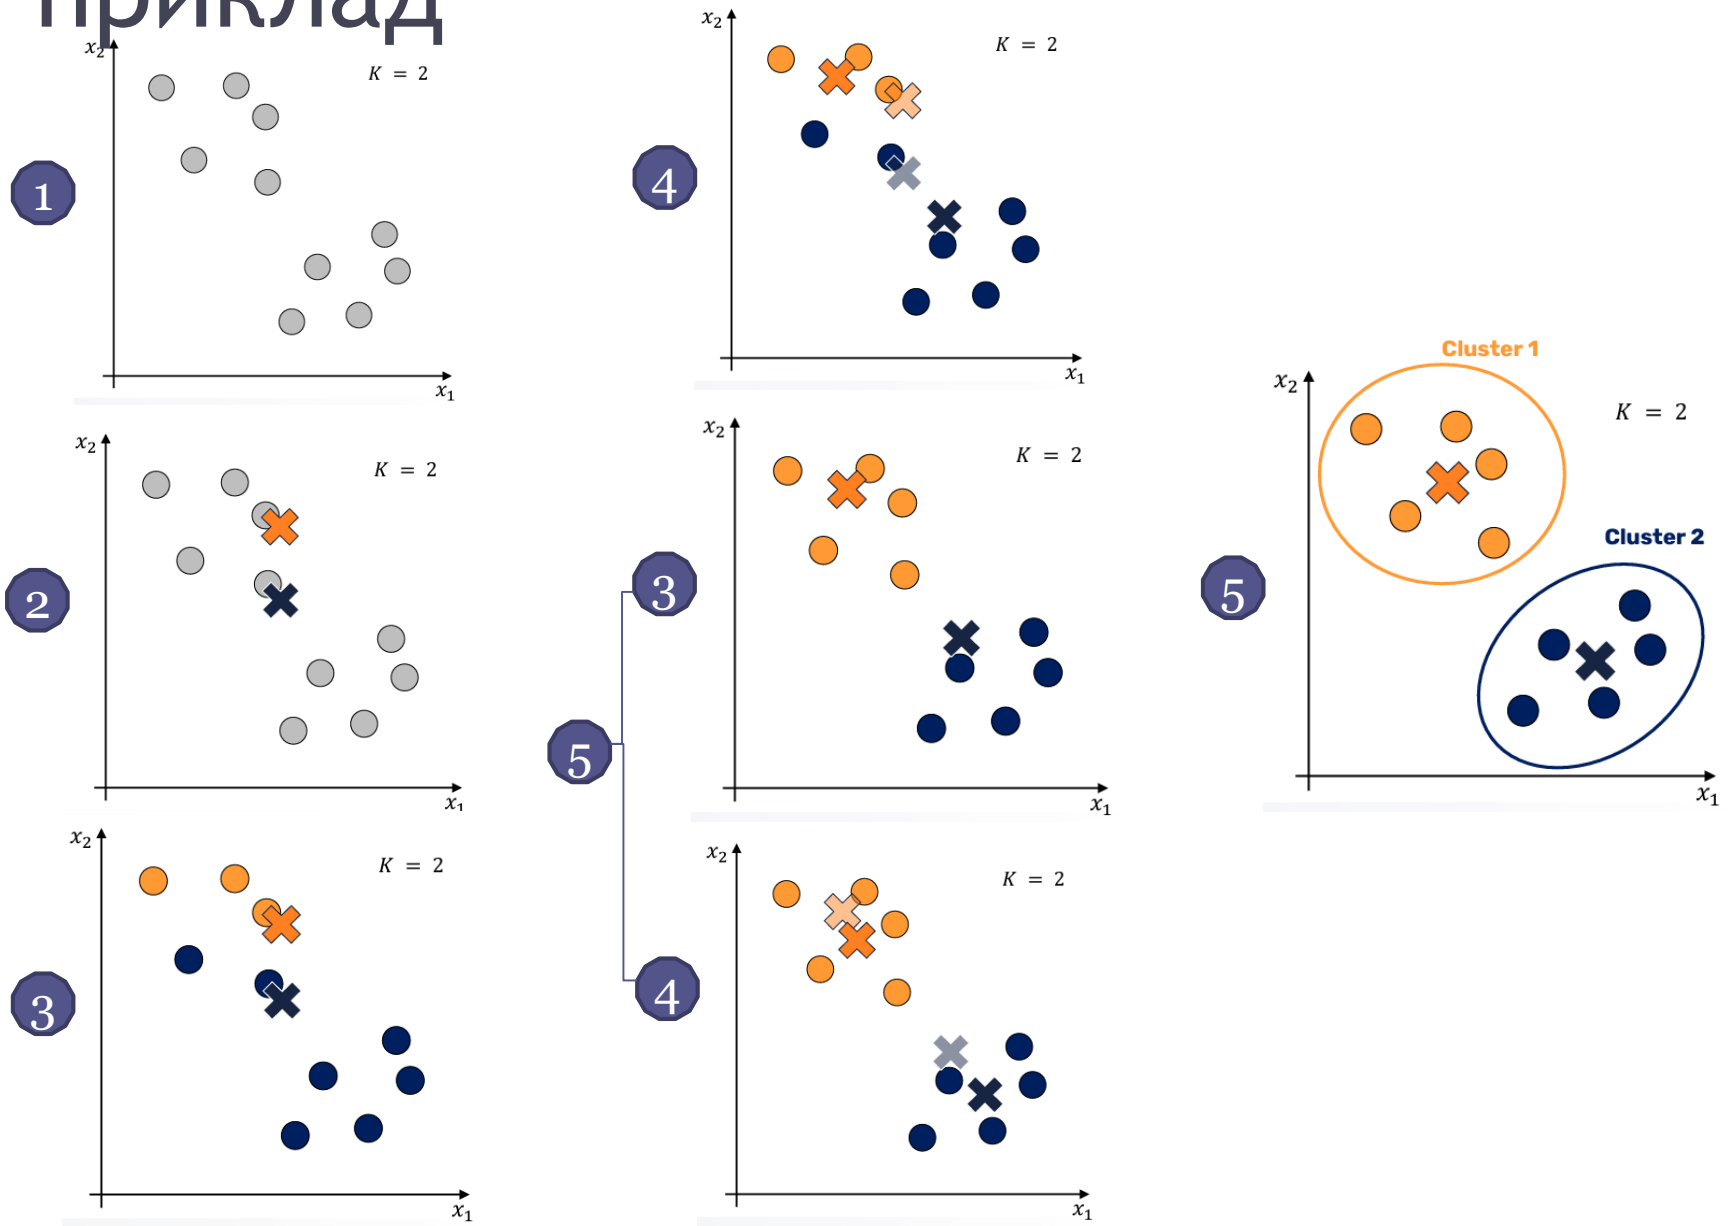

K-Means: переваги

- Простий: легкий для розуміння та реалізації
- Ефективність: Часова складність: *O(tkn)*,
  - де n – кількість точок даних,
  - k – кількість кластерів,
  - t – кількість ітерацій
- Оскільки і *k*, і *t* малі k-середнє вважається лінійним алгоритмом
- K-means є найпопулярнішим алгоритмом кластеризації
- Зауважте, що: він завершується на локальному оптимумі, якщо використовується критерій мінімізації суми квадратів помилок (SSE). Глобальний оптимум важко знайти через складність

K-Means: проблеми

- Алгоритм застосовний, лише якщо визначено середнє
- Для категоріальних даних центроїд представлений найбільш частими значеннями
- Користувачеві необхідно вказати *K*
- Алгоритм чутливий до викидів
  - Викиди – це точки даних, які знаходяться дуже далеко від інших точок даних
  - Викиди можуть бути помилками в даних або деякими спеціальними точками даних із дуже різними значеннями

K-Means: проблеми

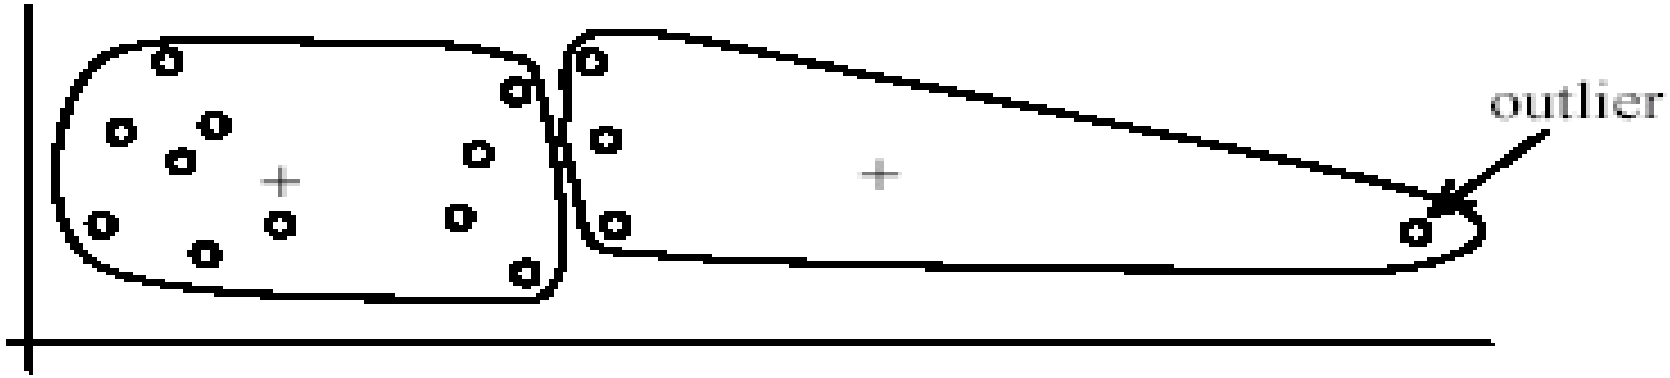

(A): Undesirable clusters

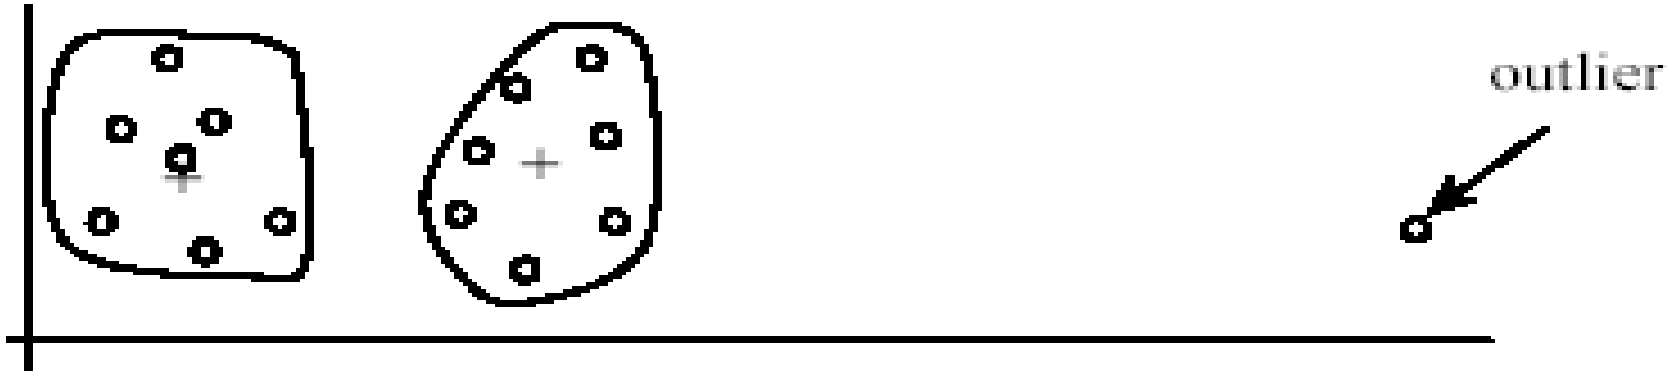

(B): Ideal clusters

K-Means: проблеми

- Одним із методів є видалення деяких точок даних у процесі кластеризації, які знаходяться набагато далі від центроїдів, ніж інші точки даних
  - Щоб бути впевненими, ми можемо захотіти відстежувати ці можливі викиди протягом кількох ітерацій, а потім вирішити їх видалити
- Інший метод полягає у виконанні випадкової вибірки. Оскільки під час вибірки ми обираємо лише невелику підмножину точок даних, ймовірність вибору викиду дуже мала
  - Призначте решту точок даних кластерам шляхом порівняння відстані чи подібності або класифікації

K-Means: проблеми

Алгоритм чутливий до початкових значень

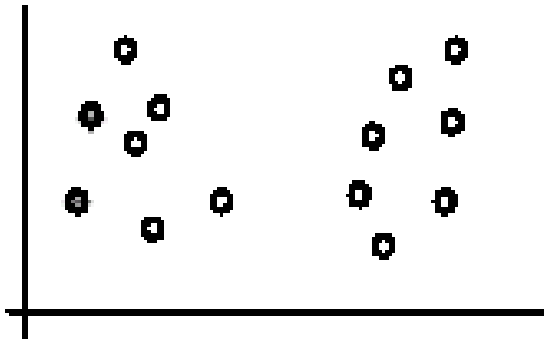

(A). Random selection of seeds (centroids)

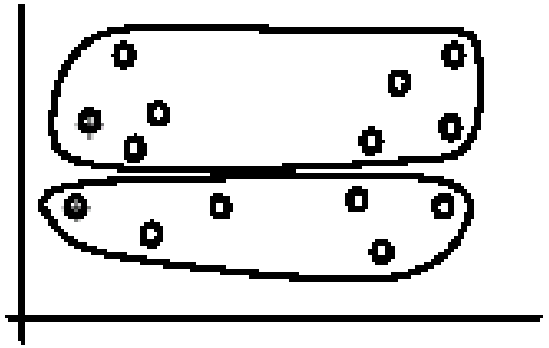

(B). Iteration 1

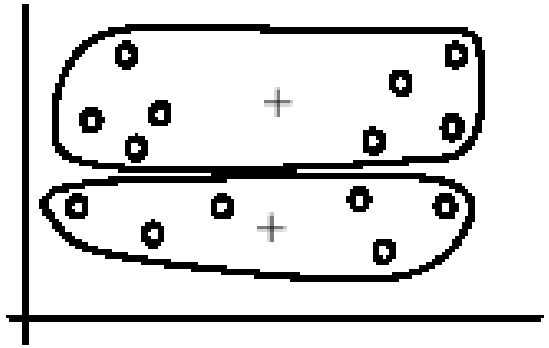

(C). Iteration 2

K-Means: проблеми

Алгоритм чутливий до початкових значень

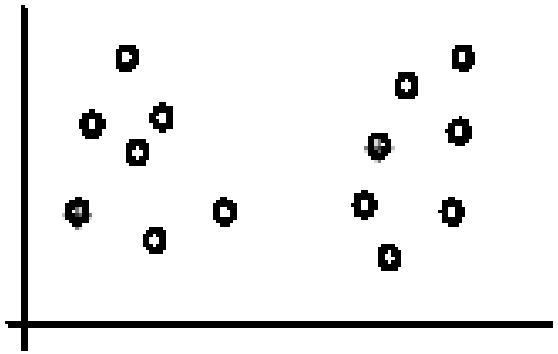

(A). Random selection of *k* seeds (centroids)

Якщо ми використовуємо різну ініціалізацію: хороші результати

Є кілька способів, які допоможуть вибрати хорошу ініціалізацію

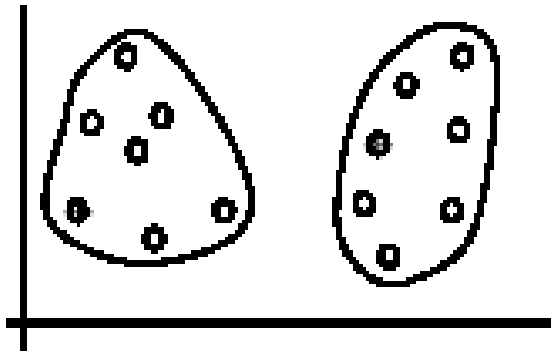

(B). Iteration 1

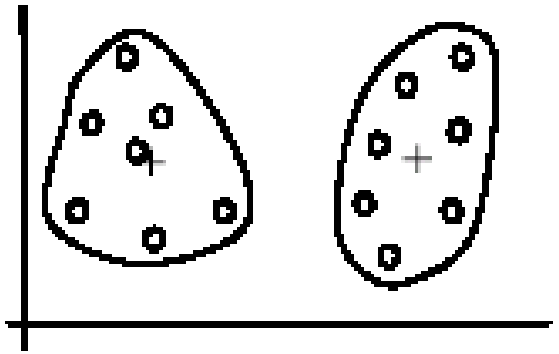

(C). Iteration 2

K-Means: проблеми

Алгоритм k-середніх не підходить для виявлення кластерів, які не є гіпереліпсоїдами (або гіперсферами)

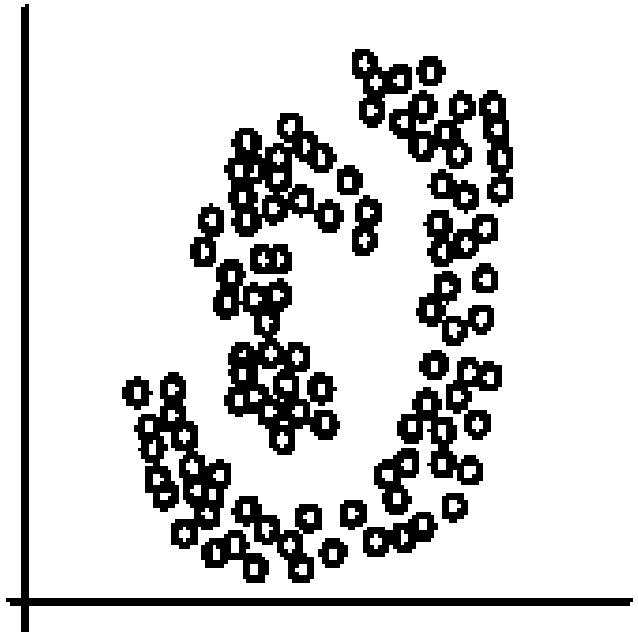

(A): Two natural clusters

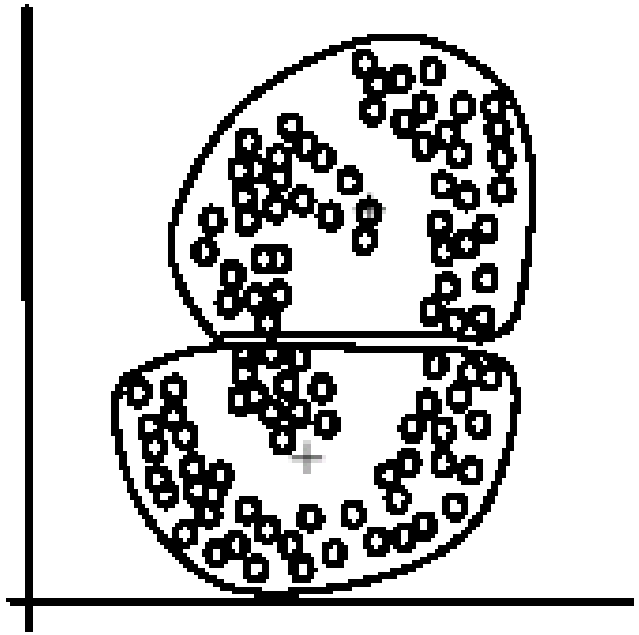

(B): *k*-means clusters

Зменшення розмірності даних: Principal Components Analysis

Аналіз головних компонентів (PCA), інструмент, який використовується для візуалізації даних або попередньої обробки даних (зменшення розмірності) перед застосуванням контрольованих методів

Набори даних для машинного навчання зазвичай містять велику кількість функцій, але такі багатовимірні простори функцій не завжди корисні. Загалом, не всі функції є однаково важливими, і є певні особливості, які спричиняють великий відсоток дисперсії в наборі даних. Алгоритми зменшення розмірності спрямовані на зменшення розмірності простору ознак до частки вихідної кількості розмірів. При цьому функції з високою дисперсією все ще зберігаються, але перебувають у трансформованому просторі ознак. А аналіз головних компонент (**Principal Component Analysis, PCA**) є одним із найпопулярніших алгоритмів зменшення розмірності

- **Ідея:** великий набір корельованих змінних, головні компоненти дозволяють узагальнити цей набір меншим числом репрезентативних змінних

- Тож PCA служить для
  - зменшення розмірності: попередня обробка даних перед застосуванням контрольованих методів
  - Стиснення даних (зображень та відео) із втратами
  - Вилучення ознак
  - Інструмент візуалізації даних

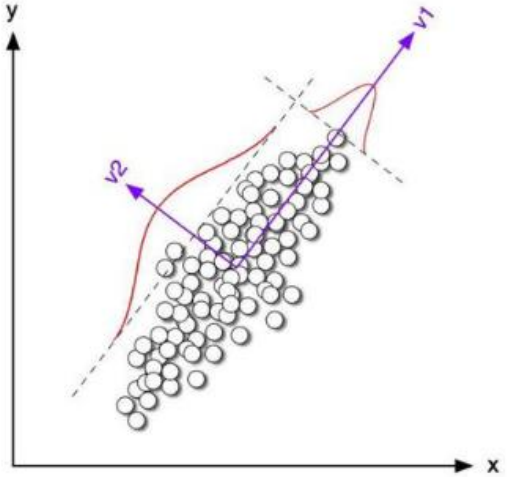

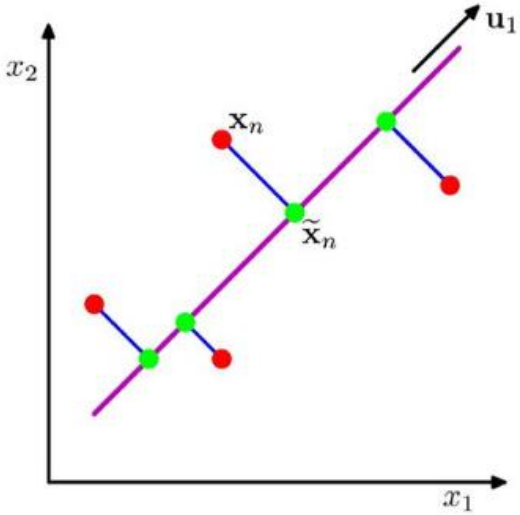

PCA

- PCA - це статистичний метод, який дозволяє скоротити розмірність даних, зберігаючи при цьому найбільшу кількість інформації

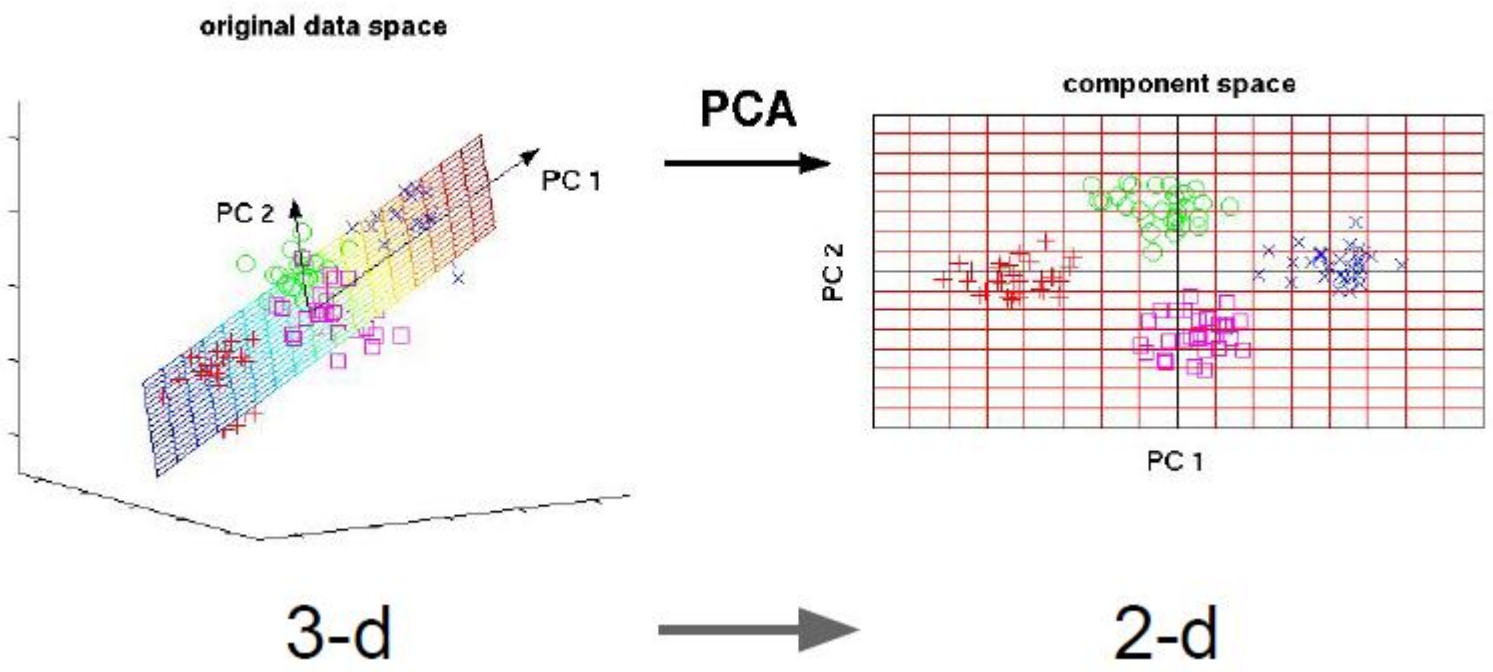

PCA

- У якому напрямку краще робити проекцію даних?
- Виберіть напрямок, який мінімізує похибку проекції
- Цей напрям також є тим, за яким дані найбільше відрізняються

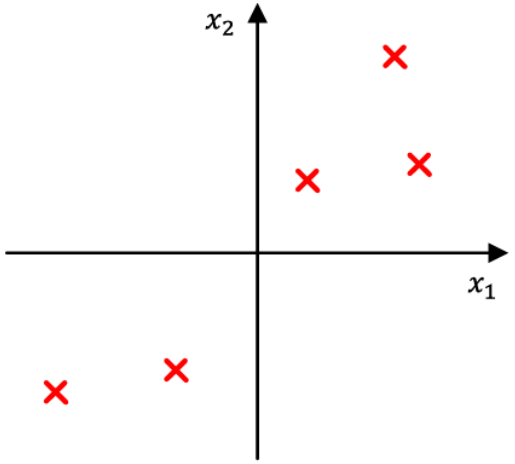

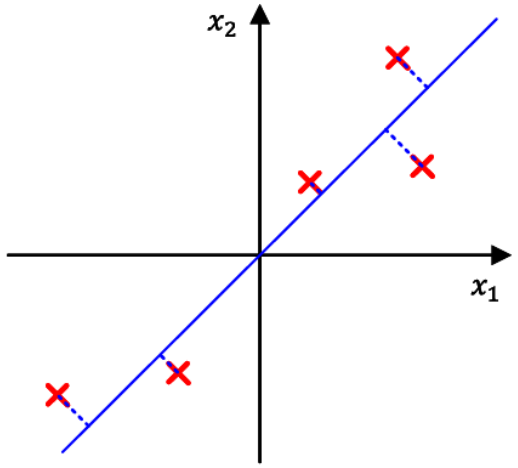

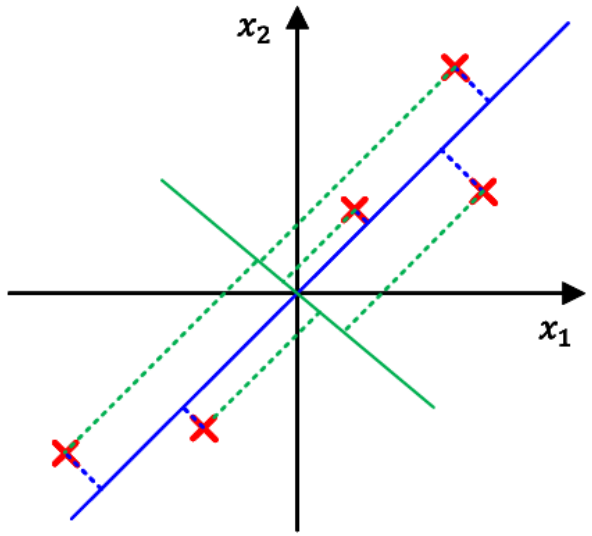

PCA

- Ортогональна проекція даних, таким чином, щоб дисперсія прогнозованих даних була максимальною
- Завдання знайти таке ортогональне перетворення в нову систему координат, для якого були б вірні такі умови:
  - Вибіркова дисперсія даних уздовж першої координати максимальна (цю координату називають першою головною компонентою)
  - Вибіркова дисперсія даних уздовж другої координати максимальна за умови ортогональності першої координати (другий головний компонент)
  - Тому спочатку видаліть всю мінливість уздовж першого компонента, а потім знайдіть наступний напрямок найбільшої мінливості
  - І так далі …

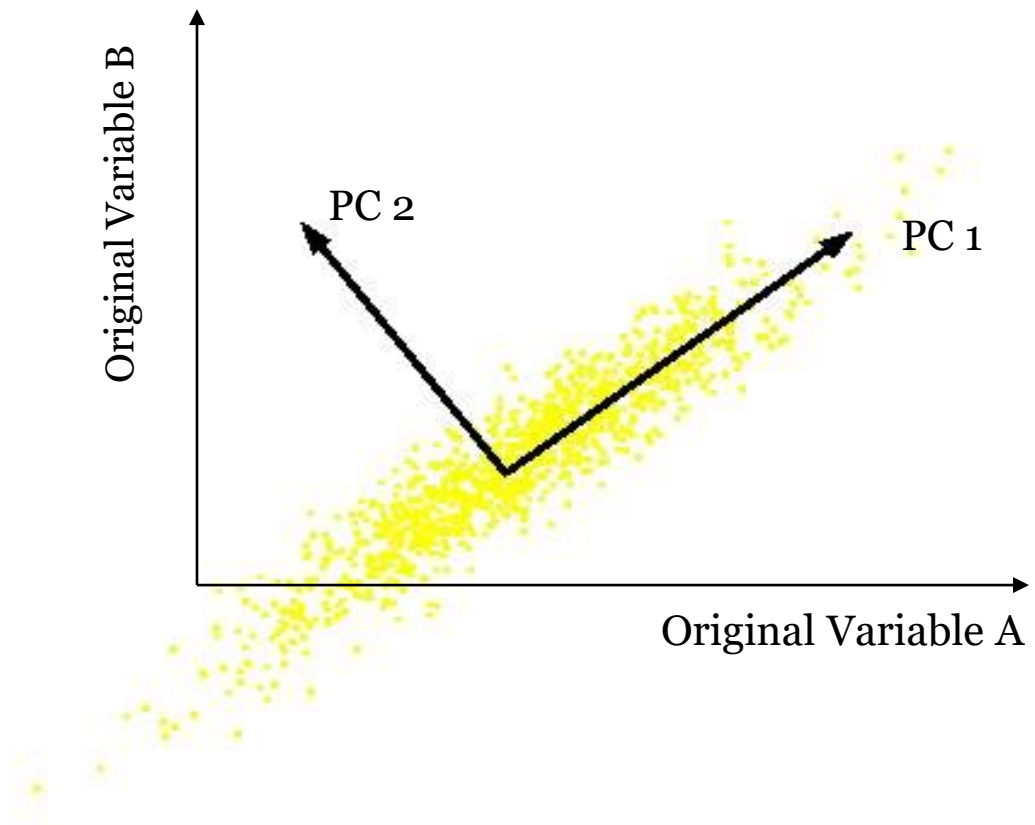

Ортогональні напрямки найбільшої дисперсії в даних

Проекції вздовж PC1 найбільше розрізняють дані вздовж однієї осі

PCA: обчислення компонентів

- Точки даних є векторами в багатовимірному просторі
- Проекція вектора **x** на вісь (вимір) **u** є **u.x**
- Напрямок найбільшої мінливості — це напрямок, у якому середній квадрат проекції найбільший
  - тобто **u** такий, що $E((\mathbf{u.x})^2)$ по всьому **x** є максимальним
  - (для спрощення ми віднімаємо середнє значення вздовж кожного виміру та центруємо початкову систему осей у центроїді всіх точок даних)
  - Цей напрямок **u** є напрямком першої головної компоненти

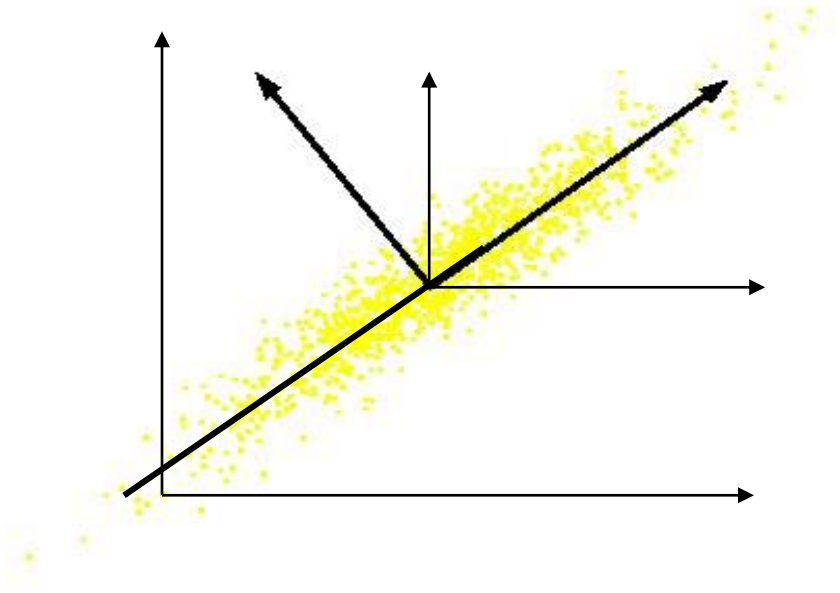

PCA: обчислення компонентів

- $E((\mathbf{u.x})^2) = E((\mathbf{u.x})(\mathbf{u.x})^T) = E(\mathbf{u.x.x}^T.\mathbf{u}^T)$
- Матриця $\mathbf{C} = \mathbf{x.x}^T$ містить кореляції (подібності) вихідних осей на основі того, як значення даних проецируються на них
- Тому ми шукаємо **w** що максимізує $\mathbf{uCu}^T$, за умови що **u** є одиничною довжиною
- Він максимізується, коли **w** є головним власним вектором матриці **C**, у якому випадку
  - $\mathbf{uCu}^T = \mathbf{u}\lambda\mathbf{u}^T = \lambda$ якщо **u** є одиничною довжиною, де λ є головним власним значенням кореляційної матриці C
  - Власне значення вказує на кількість мінливості, зафіксованої в цьому вимірі

PCA: Singular Value Decomposition

Математичний зміст методу головних компонентів — це спектральне розкладання матриці коваріації **C**, тобто подання простору даних у вигляді суми взаємно ортогональних власних підпросторів **C**, а самої матриці **C** — у вигляді лінійної комбінації ортогональних проекторів на ці підпростори з коефіцієнтами **λ**

Одиничні значення у матриці SVD можна використовувати для обчислення дисперсії даних, поясненої кожним головним компонентом

- Аналогічно для наступної осі тощо
- Таким чином, нові осі є власними векторами матриці кореляції вихідних змінних, яка фіксує подібність вихідних змінних на основі того, як вибірки даних проектуються на них

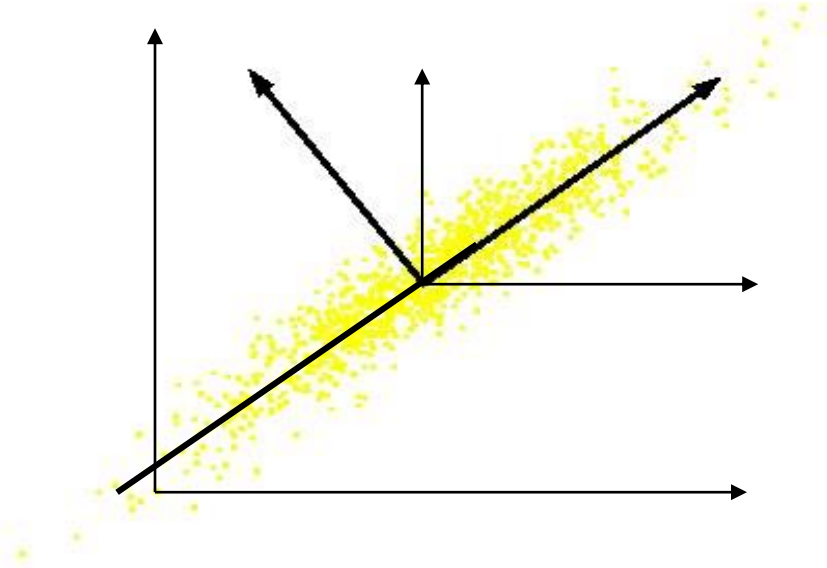

- Геометрично: центрування з подальшим обертанням
  - Лінійне перетворення

PCA: приклад

Якщо у вас є лише 2 вимірювання для ваших об'єктів, то хороший спосіб візуалізації даних – це побудувати дані на площині, використовуючи два вимірювання як осі

Наприклад, дві важливі особливості планет нашої Сонячної системи:

- відстань до Сонця
- екваторіальний діаметр

Створення діаграми даних дасть вам гарне представлення з очевидними властивостями:

- близькі точки означають подібні планети
- далеко розташовані точки означають різні планети
- опуклі точки оболонки означають «крайні» планети

А тепер припустімо, що є ще одна особливість планети, яку ви вважаєте не менш важливою:

- щільність

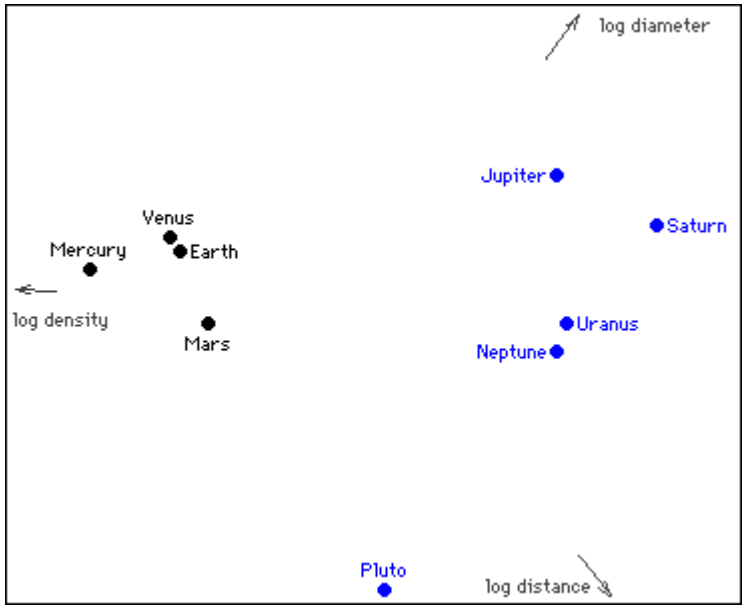

Погляд на дані після PCA підтверджує, що Венера є двійником Землі, що Уран і Нептун також схожі, і що Плутон є досить дивним об'єктом

PCA: приклад

PCA також може бути використаний для покращення кластеризації даних

Кластеризація без PCA

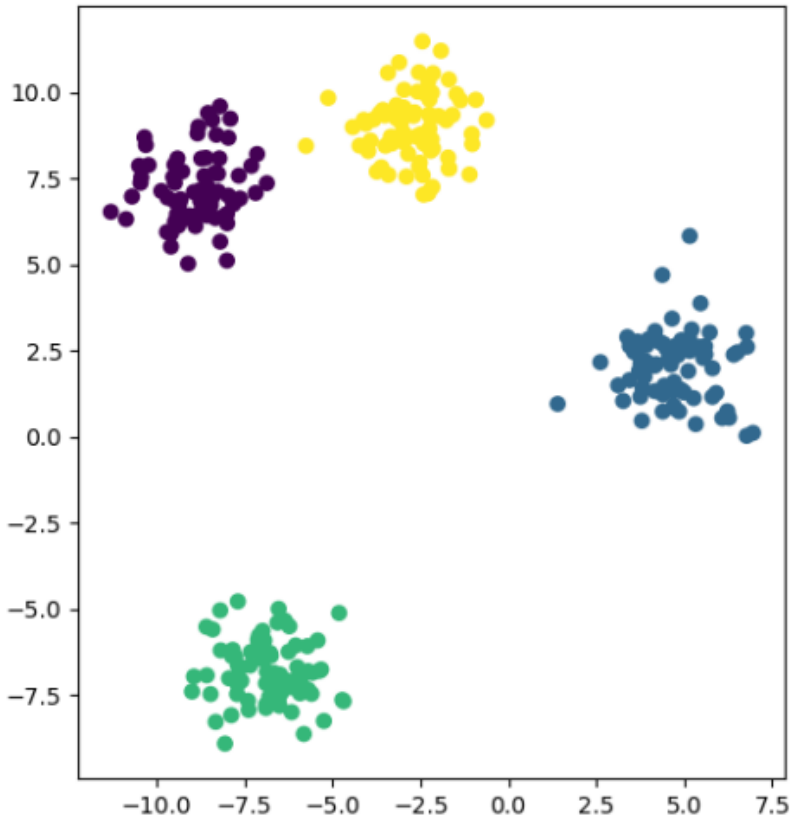

Кластеризація після PCA

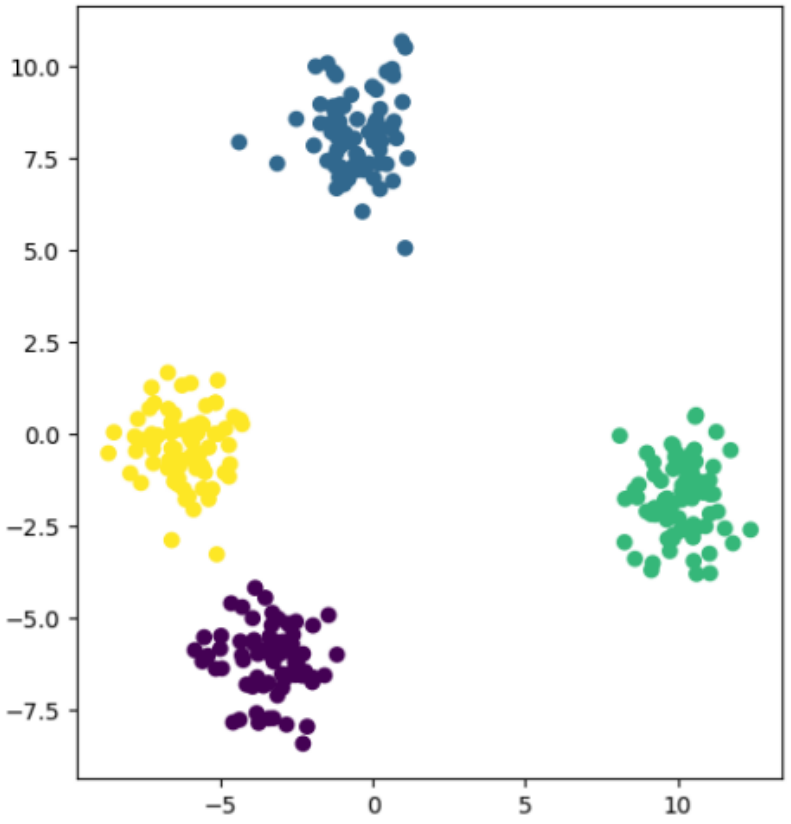

Самоорганізовані карти Кохонена

- Карта Кохонена, що самоорганізується (Self-organizing map - SOM) – змагальна нейронна мережа з навчанням без вчителя, що виконує завдання візуалізації та кластеризації
- Ідея мережі запропонована фінським ученим Т.Кохоненом
- Принципово відрізняється від усіх інших типів мереж, мережа Кохонена з навчанням без вчителя – значення ваги та/або порогів змінюються на підставі тільки вхідних навчальних даних (вихідні значення не потрібні і, якщо вони присутні, ігноруються і не використовуються – звідси самоорганізація чи самонавчання)
- Основний принцип роботи мереж - введення в правило навчання нейрона інформації щодо його розташування
- Унікальність мереж Кохонена - вони є методом проектування багатовимірного простору в простір з більш низькою розмірністю (найчастіше двовимірне)
- Дозволяють також подати отриману інформацію у простій та наочній формі шляхом нанесення розмальовки

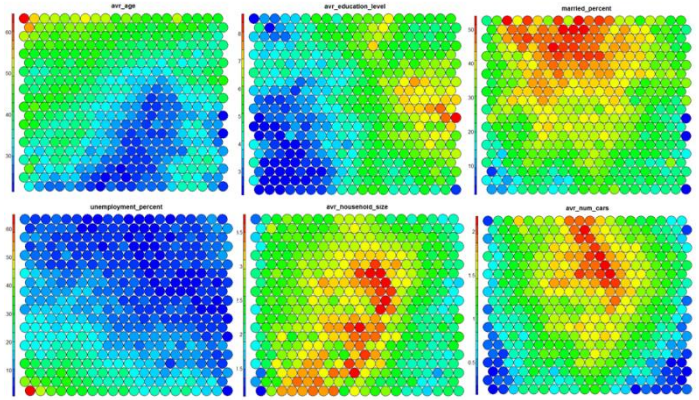

Самоорганізовані карти Кохонена

- Вона являє собою два шари: вхідний і вихідний (карта, що самоорганізується)
- Карта, що самоорганізується, складається з нейронів, які зазвичай розташовують у вершинах регулярної решітки з квадратними або шестикутними осередками.
- Їхня кількість задається аналітиком. Кожен із вузлів описується двома векторами.
- Перший – т.з. вектор ваги m, що має таку ж розмірність, як і вхідні дані
- Другий — вектор r, що є координатами вузла на карті

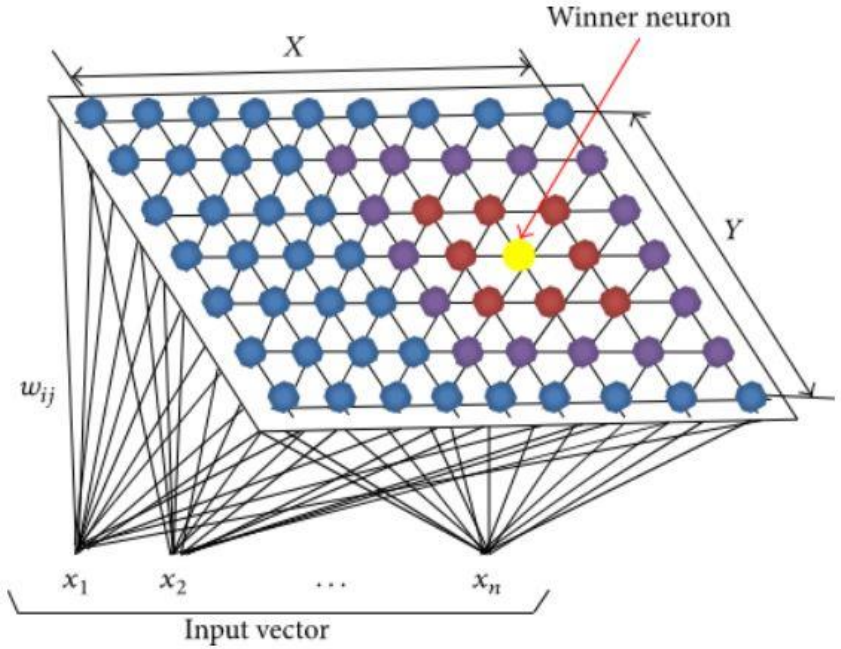

Самоорганізовані карти Кохонена

- В основі ідеї мережі Кохонена лежить аналогія із властивостями людського мозку. Кора головного мозку людини є плоским листом і згорнута складками. Таким чином, можна сказати, що вона має певні топологічні властивості (ділянки, відповідальні за близькі частини тіла, примикають один до одного і все зображення людського тіла відображається на цю двовимірну поверхню)

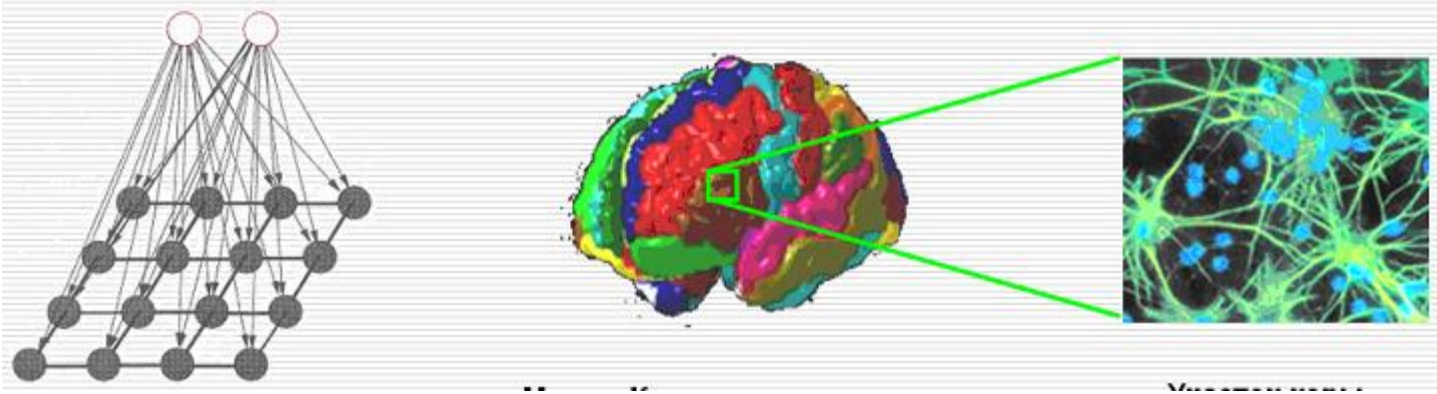

Навчання нейромережі Кохонена

- Мережа Кохонена навчається методом послідовних наближень
- У процесі навчання таких мереж на входи подаються дані, але мережа у своїй підлаштовується під еталонне значення виходу, а під закономірності у вхідних даних. Починається навчання з обраного випадковим чином вихідного розташування центрів
- У процесі послідовної подачі на вхід мережі навчальних прикладів визначається найбільш схожий нейрон (той, у якого скалярний добуток ваги і поданого на вхід вектора мінімально). Цей нейрон оголошується переможцем і є центром при підстроюванні ваг у сусідніх нейронів. Таке правило навчання передбачає "змагання" навчання з урахуванням відстані нейронів від «нейрона-переможця»

$$\| \mathbf{x} - \mathbf{w_c} \| = \min_i \{ \| \mathbf{x} - \mathbf{w_i} \| \}$$

- Навчання при цьому полягає не в мінімізації помилки, а в підстроюванні ваг (внутрішніх параметрів нейронної мережі) для найбільшого збігу з вхідними даними

$$w_i(t+1) = \mathbf{w}_i(t) + h_{ci}(t) * [\mathbf{x}(t) - \mathbf{w}(t)],$$

де t позначає номер епохи (дискретний час). При цьому вектор $x(t)$ вибирається випадково з навчальної вибірки на ітерації t. Функція $h(t)$ називається функцією сусідства нейронів і є незростаючою функцією від часу і відстані між нейроном-переможцем і сусідніми нейронами в сітці. Ця функція розбивається на дві частини: власне функцію відстані та функції швидкості навчання від часу, де r визначає положення нейрона у сітці

Області застосування Unsupervised Learning

Моделювання, прогнозування, пошук закономірностей у великих масивах даних, виявлення наборів незалежних ознак та стиснення інформації :

- виділення надійних партнерів
- передбачення банкрутств
- перевірка кредитоспроможності
- визначення перспективного товару
- аналіз результатів маркетингових досліджень, сегментація ринків збуту, товарів та послуг
- обробка символьної інформації

тощо

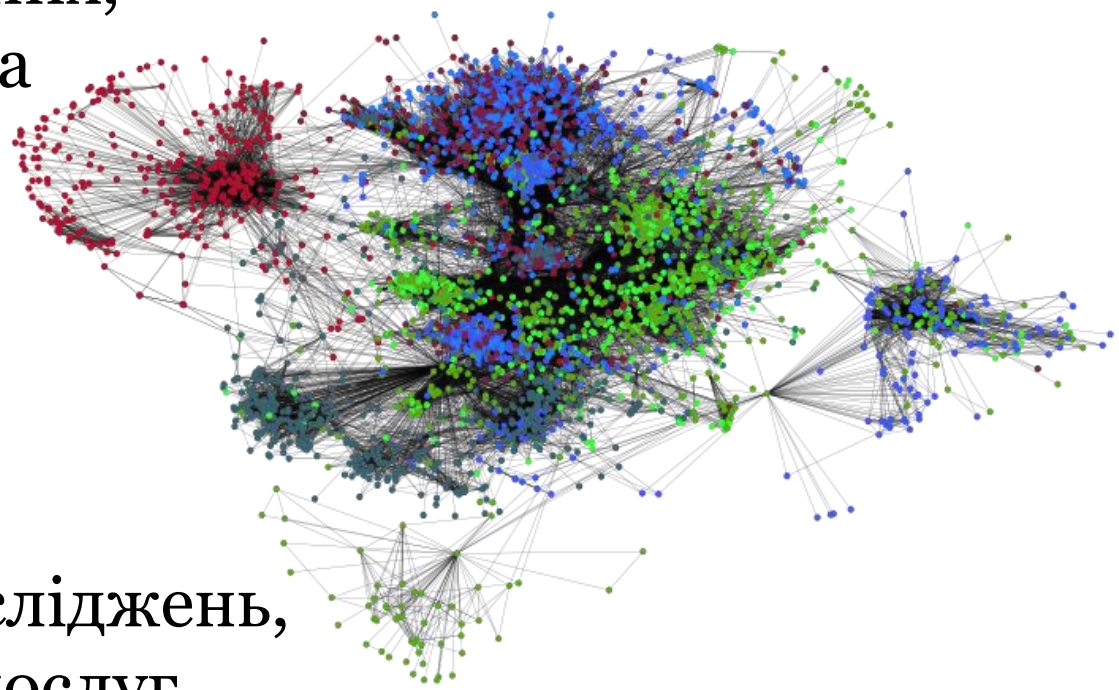

Практична работа

Практична 1

- Вступ до неконтрольованого навчання
- Метод головних компонент PCA
- Рішення задачі кластеризації K-Means

Практична 2

- Приклад кластеризації на реальних даних
- Обробка зображень за допомогою кластеризації

- Бібліотеки
  - Scikit-learn
  - OpenCV