ROC-крива

Крива робочих характеристик (англ. Receiver Operating Characteristics curve). Використовується для аналізу поведінки класифікаторів при різних порогових значеннях.

Дозволяє розглянути всі порогові значення для даного класифікатора. Показує частку хибно позитивних прикладів (англ. False positive rate, FPR) в порівнянні з часткою істинно позитивних прикладів (англ. True positive rate, TPR).

У випадку багатокласової класифікації поняття TPR або FPR отримується лише після бінарного виводу. Це можна зробити двома способами:

- схема One-v-Rest порівнює кожен клас з усіма іншими (вважається одним);
- схема «один проти одного» порівнює кожну унікальну попарну комбінацію класів.

Показники Precision та Recall також не обмежуються бінарною класифікацією. Їх також можна використовувати у задачах багатокласової класифікації.

Можливі способи

1) Можна розрахувати Precision та Recall для кожного класу окремо. Таким чином, отримаємо кілька показників відповідно до кількості класів у наборі даних.

$$Precision_{class\ A} = \frac{TP_{class\ A}}{TP_{class\ A} + FP_{class\ A}} \qquad Recall_{class\ A} = \frac{TP_{class\ A}}{TP_{class\ A} + FN_{class\ A}}$$

2) Можна «усереднити» Precision та Recall для всіх класів, щоб отримати одне число. Для усереднення точності можна використовувати різні методи, наприклад макро- або мікроусереднення.

One hot encoding

```
from sklearn.preprocessing import LabelBinarizer

label_binarizer = LabelBinarizer().fit(y_train)
y_onehot_test = label_binarizer.transform(y_test)
y_onehot_train = label_binarizer.transform(y_train)
y_onehot_test
```

```
y_test
0.0s
3
3
4
3
1
1
3
4
3
1
2
1
3
3
3
3
4
2
1
3
```

```
y_onehot_test
✓ 0.0s
array([[0, 0, 1, 0],
       [0, 0, 1, 0],
       [0, 0, 0, 1],
       [0, 0, 1, 0],
       [1, 0, 0, 0],
       [1, 0, 0, 0],
       [0, 0, 1, 0],
       [0, 0, 0, 1],
       [0, 0, 1, 0],
       [1, 0, 0, 0],
       [0, 1, 0, 0],
       [1, 0, 0, 0],
       [0, 0, 1, 0],
       [0, 0, 1, 0],
       [0, 0, 1, 0],
       [0, 0, 1, 0],
       [0, 0, 0, 1],
       [0, 1, 0, 0],
       [1, 0, 0, 0],
       [0, 0, 1, 0]])
```

ROC-крива

Відображає долю істино позитивних класифікацій по відношенню до хибно позитивних

Задача про фрукти: ROC

```
from sklearn import metrics

fig,ax=plt.subplots();
scores=knn.predict_proba(X_train)
fpr = dict()
tpr = dict()
thresholds = dict()
roc_auc = dict()
for i in range(len(fruits.fruit_name.unique())):
    fpr[i], tpr[i], thresholds[i] = metrics.roc_curve(y_onehot_train[:,i], scores[:,i])
    roc_auc[i] = metrics.auc(fpr[i], tpr[i])
    ax.plot(fpr[i], tpr[i], label='{}: AUC = {:.3f}'.format(fruits.fruit_name.unique()[i],roc_auc[i]))
ax.legend()
ax.plot(fpr[0], fpr[0], linestyle='--',label='Doomy classifier')
ax.grid(alpha=0.3)
ax.set_title('ROC Curve')
ax.set_xlabel('False positive rate, FPR (1-Specificity)')
ax.set_ylabel('True positive rate, TPR (Recall)')
```

✓ 0.1s

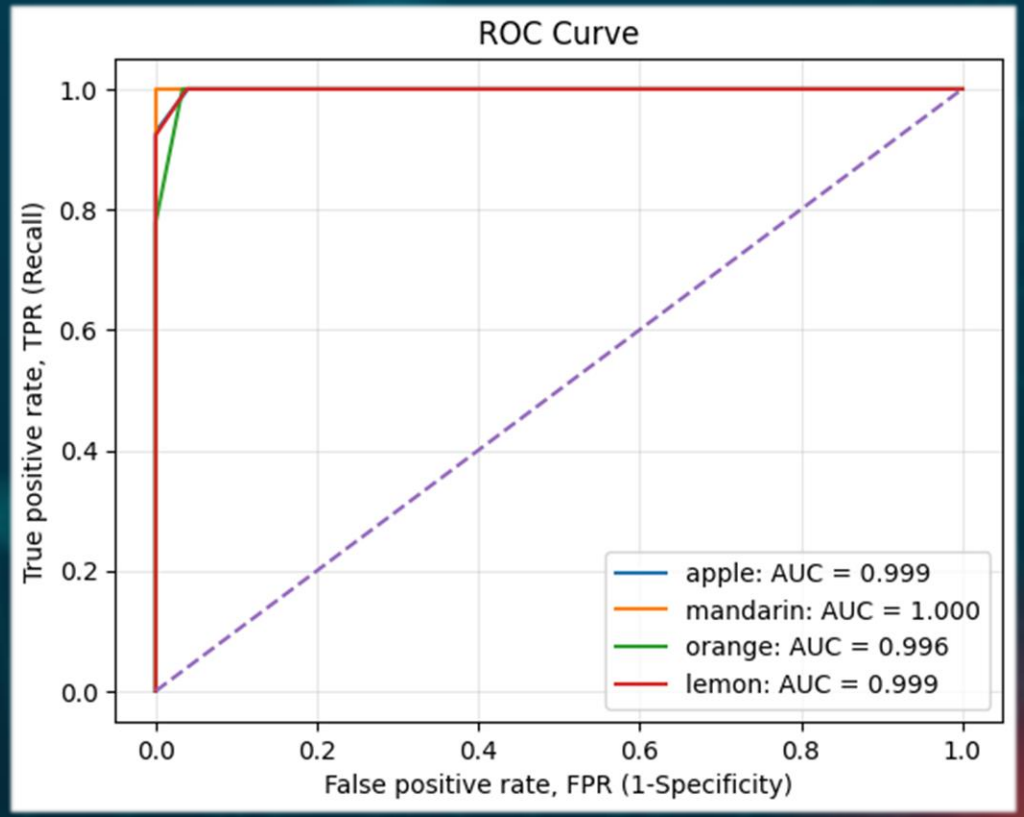

$$TPR = \frac{TP}{TP + FN} = Recall$$

$$FPR = \frac{FP}{FP + TN} = Specificity$$

Частка FPR - це пропорція негативних зразків, які були некоректно класифіковані як позитивні.

$$FPR = 1 - TNR$$

де TNR - частка істинно негативних класифікацій (True Negative Rate), що представляє собою пропорцію негативних зразків, які були коректно класифіковані як негативні.

Частка TNR також називається специфічністю (Specificity). Отже,ROC-крива зображає чутливість (Sensitivity), тобто повноту, в порівнянні з різницею 1 - Specificity.

Пунктирна лінія по діагоналі представляє ROC-криву чисто випадкового класифікатора. Хороший класифікатор тримається від зазначеної лінії настільки далеко, наскільки це можливо (прагнучи до лівого верхнього кута).

Один із способів порівняння класифікаторів передбачає вимір площі під кривою (англ. Area Under the Curve - AUC).

Бездоганний класифікатор матиме площу під ROC-кривою (ROC-AUC), що дорівнює 1, тоді як чисто випадковий класифікатор - площу 0.5.

Графік ROC допомагає прийняти рішення про те, де встановити поріг класифікації, щоб максимізувати істинно позитивний рівень або мінімізувати псевдопозитивний показник.

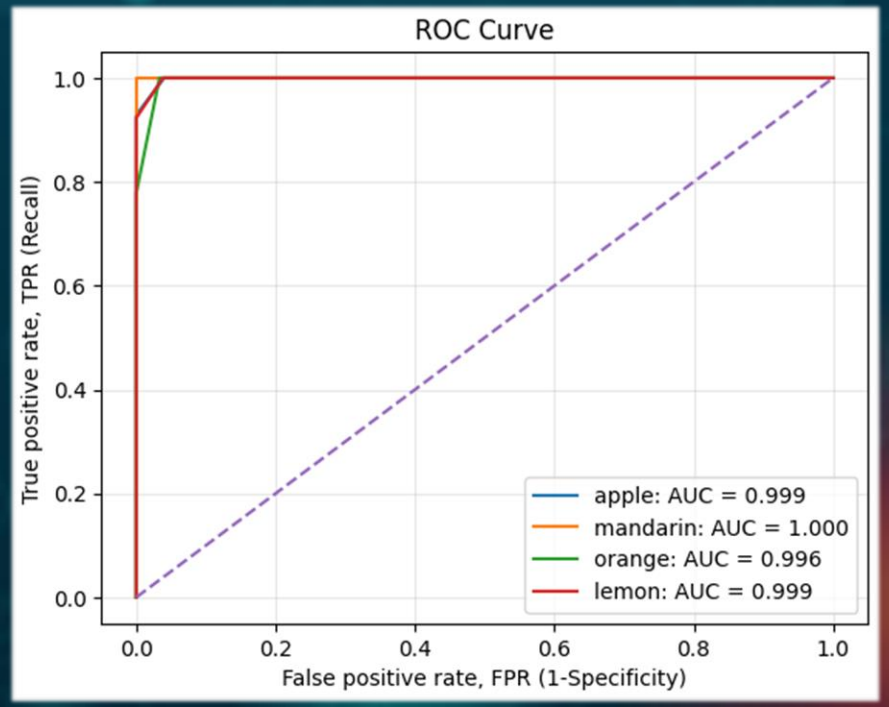

Крива Precision-Recall

Чутливість до співвідношення класів. Розглянемо задачу виділення математичних статей з множини наукових статей. Припустимо, що є 1.000.100 статей, з яких лише 100 математичних.

Якщо вдасться побудувати алгоритм A1(x), що ідеально вирішує завдання, то його TPR буде дорівнює одиниці, а FPR - нулю.

Розглянемо тепер поганий алгоритм, що дає позитивну відповідь на 95 математичних і 50.000 нематематичних статтях. Такий алгоритм абсолютно марний, але при цьому має TPR = 0.95 і FPR = 0.05, що дуже близько до показників ідеального алгоритму. Таким чином, якщо позитивний клас істотно менше за розміром, то AUC-ROC може давати неадекватну оцінку якості роботи алгоритму, оскільки вимірює частку невірно прийнятих об'єктів щодо загального числа негативних. Так, алгоритм A2(x), що поміщає 100 релевантних документів на позиції з 50.001-й по 50.101-ю, матиме AUC-ROC 0.95.

Позбутися від зазначеної проблеми з незбалансованими класами можна, перейшовши від ROC-кривої до Precison-recall (PR) PR-кривої. Вона визначається аналогічно до ROC-кривої, тільки по осях відкладаються НЕ FPR і TPR, а повнота (по осі абсцис) і точність (по осі ординат). Критерієм якості сімейства алгоритмів виступає площа під PR-кривою (англ. Area Under the Curve - AUC-PR).

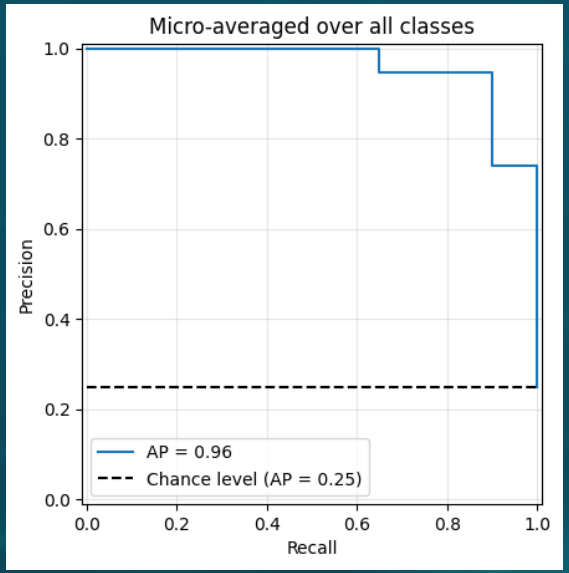

Задача про фрукти: Precision-Recall Curve

Усереднення Precision та Recall

Замість багатьох метрик для кожного класу можна використовувати «середні» метрики. Два популярних підходи — це макро- та мікроусереднення.

Макроусереднення : вимірюються показники для кожного класу, знаходиться середнє

$$Precision_{macro} = \frac{Presision_{class\ A} + \cdots + Precision_{class\ N}}{N}$$

$$Recall_{macro} = \frac{Recall_{class\ A} + \cdots + Recall_{class\ N}}{N}$$

Мікроусереднення : обчислюють загальну кількість істинно-позитивних (TP), хибно-позитивних (FP) і хибно-негативних (FN) прогнозів у всіх класах:

- Total True Positive – це сума істинно позитивних підрахунків у всіх класах;
- Загальна кількість помилкових позитивних результатів – це сума підрахунків помилкових позитивних результатів у всіх класах;
- Total False Negative – це сума підрахунків помилкових негативів у всіх класах.

Обчислюють Precision та Recall , використовуючи і загальні показники:

$$Precision_{micro} = \frac{TP_A + \cdots + TP_N}{TP_A + FP_A + \cdots + TP_N + FP_N}$$

$$Recall_{micro} = \frac{TP_A + \cdots + TP_N}{TP_A + FN_A + \cdots + TP_N + FN_N}$$

Micro vs Macro

Якщо кількість прикладів для класів приблизно однакова, то мікро- та макроусереднення будуть приблизно однаковими.

Якщо вибірка незбалансована, то мікроусереднення дозволить оцінити модель у напряму великих класів, тоді як макроусереднення – у напряму маленьких класів (влив результатів по кожному класу на загальну оцінку однаковий).

$micro \ll macro$ ⇨ Класифікатор більше помиляється при розпізнаванні більших класів

$micro \gg macro$ ⇨ Класифікатор більше помиляється при розпізнаванні менших класів

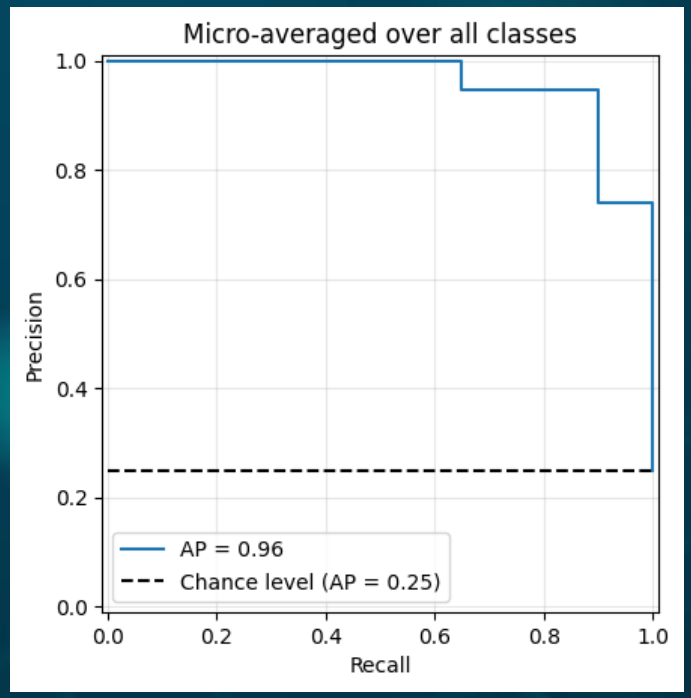

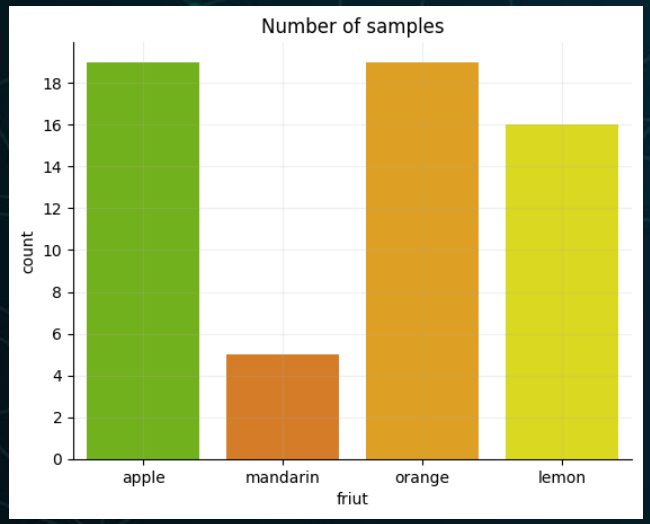

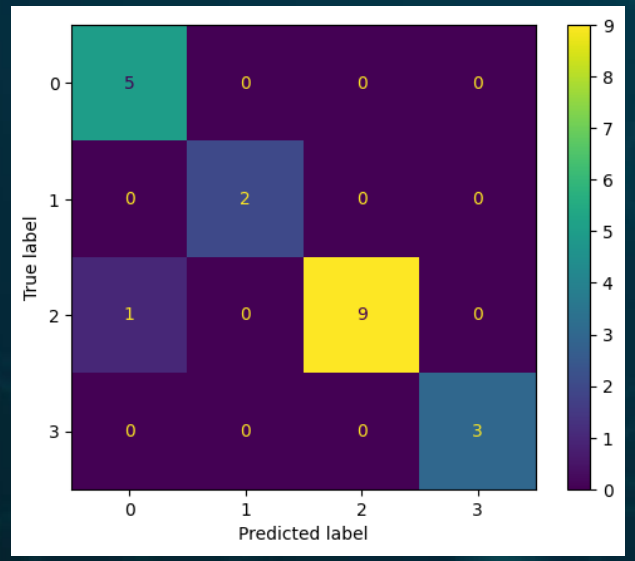

$Macro\ average = 1$

Постановка завдання регресії

По даним **n** спостережень, що є за спільною зміною двох параметрів **x** і **y** {(x,y), i=1,2,...,n} необхідно визначити аналітичну залежність **y=f(x)**, найкращим образом, що описує дані спостережень.

Вирішити задачу регресії - означає знайти алгоритм, здатний до узагальнення емпіричних фактів (до виведення загальних знань з окремих спостережень, прецедентів).

Побудова рівняння регресії здійснюється в два етапи (передбачає рішення двох задач):

- специфікація моделі (визначення вигляду аналітичної залежності **y=(x)**);
- оцінка параметрів вибраної моделі.

Модель лінійної регресії

Модель лінійної регресії *(linear regression)* - часто використовувана в статистиці модель лінійної залежності однієї змінної ***y*** від іншої, незалежної змінної ***x***, або декількох змінних.

У термінах машинного навчання ***y*** - це відповідь, а множина незалежних змінних - ознаки. Проста лінійна регресія виглядає як функція згортки множини ознак з ваговими коефіцієнтами

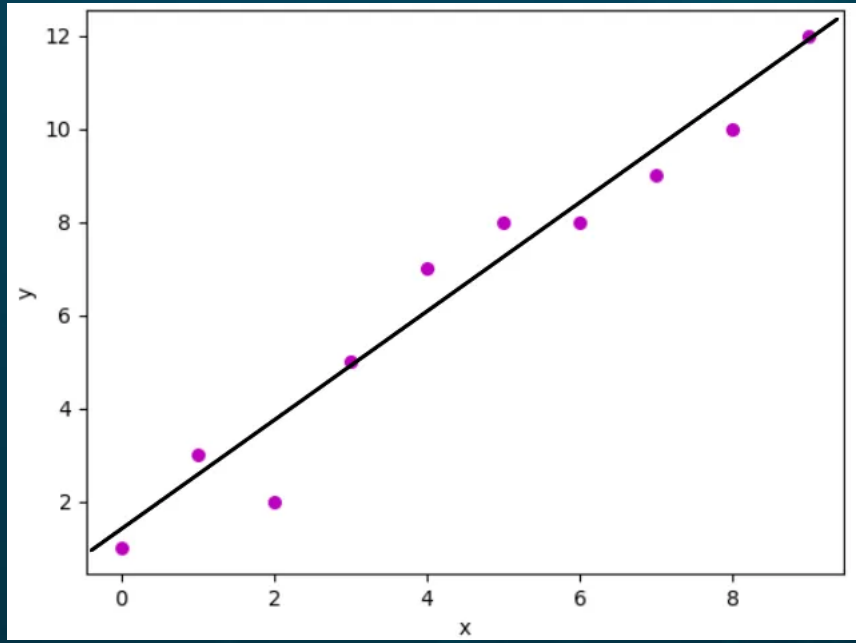

Проста модель лінійної регресії є насправді одним з найпотужніших інструментів аналізу даних.

Регресію можна використовувати в тому числі і для вирішення задачі ранжування - досить прийняти відповідь моделі за вагу об'єкта, представленого вектором **x**.

Ridge regression

By Yash Gupta

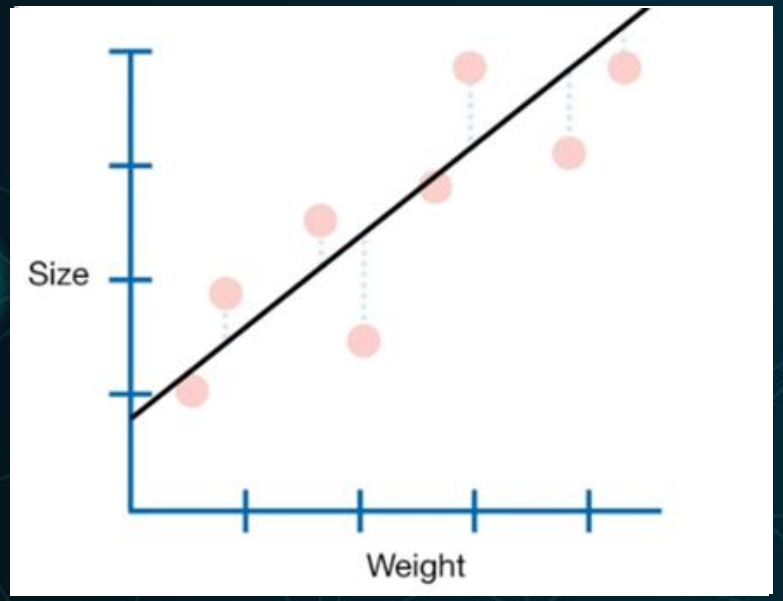

Тренувальні дані
Тестові дані

linear regression

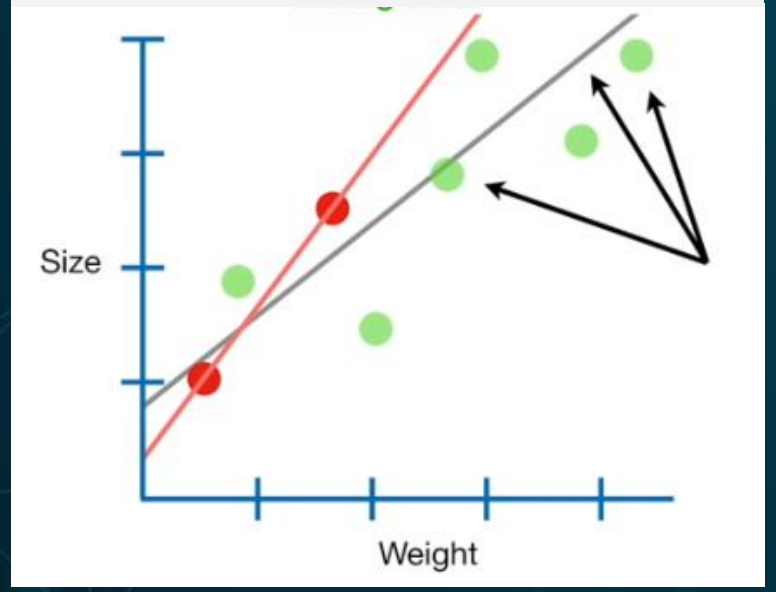

Гірше для тренувальних даних
Краще для тестових даних

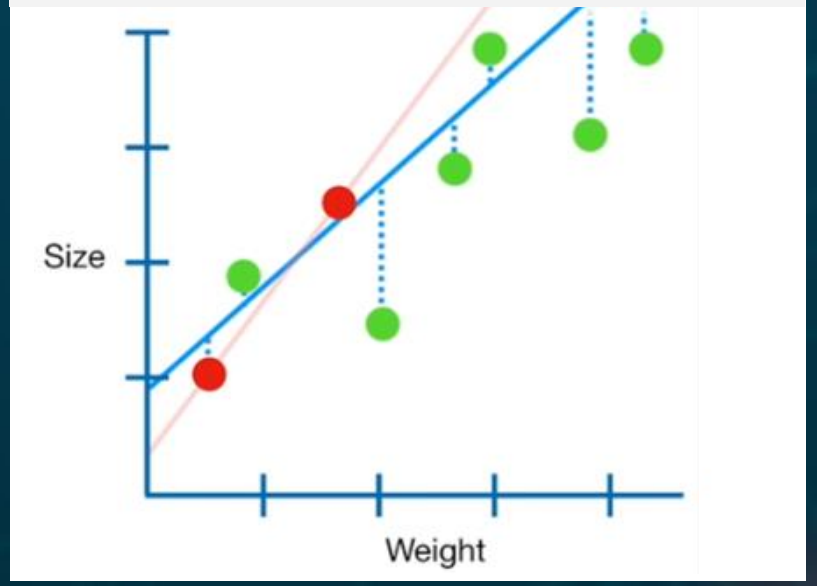

$$RSS(w,b) = \sum_{i=1}^{N} \left(y_i - (w * x_i + b)\right)^2 + \alpha * \sum_{j=1}^{p} {w_j}^2$$

Похибка
Більша α означає більшу регуляризацію

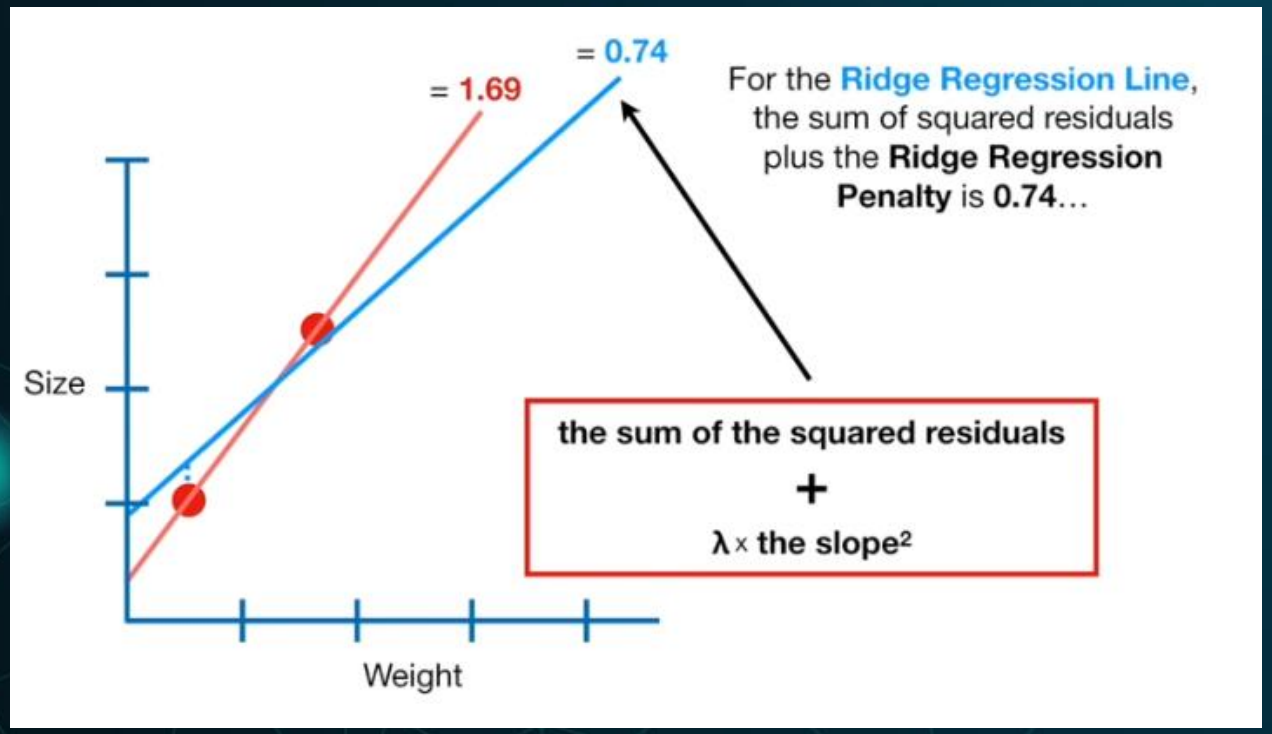

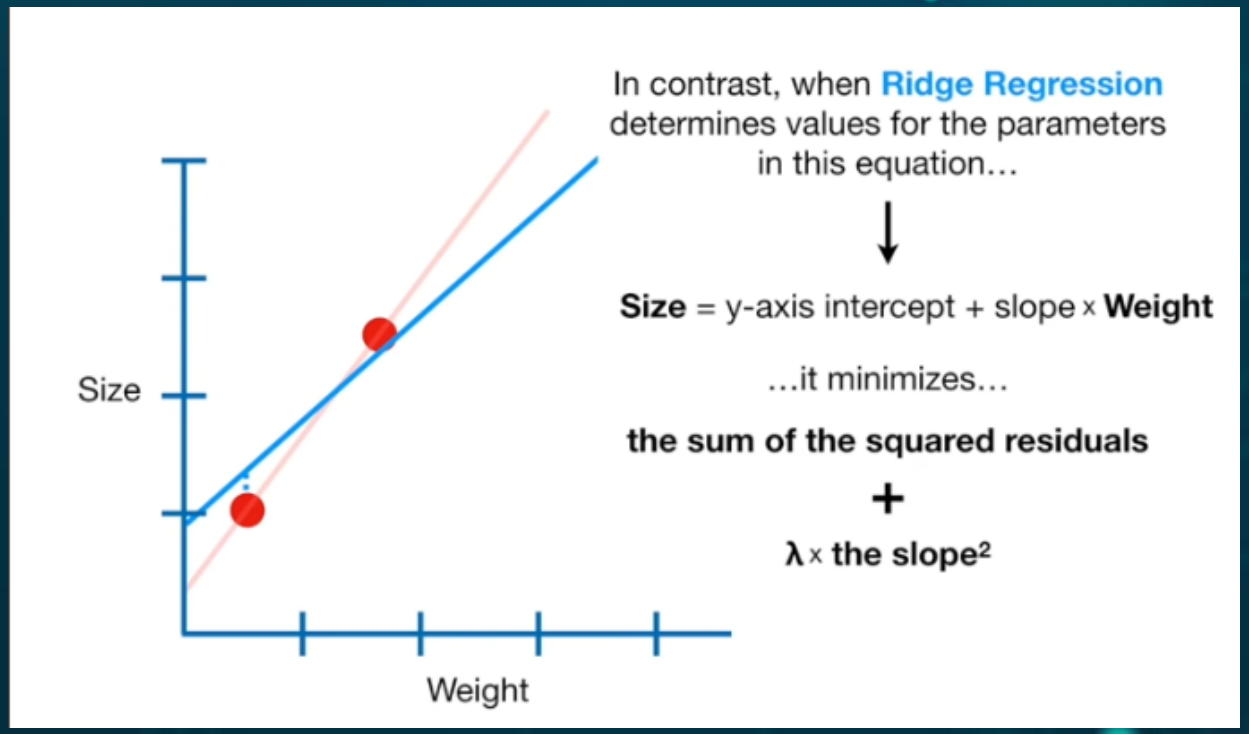

Residual sum of squares

$$RSS(w,b) = \sum_{i=1}^{N} \left(y_i - (w * x_i + b)\right)^2 + \alpha * \sum_{j=1}^{p} {w_j}^2$$

Вивчення задачі

Вивчення залежності задоволення рівнем життя від фінансового стану.

Доцільно використовувати дані **Better Life Index** від **Organisation for Economic Co-operation and Development (OECD)**
та дані щодо ВВП на душу населення **GDP** від **International Monetary Fund**

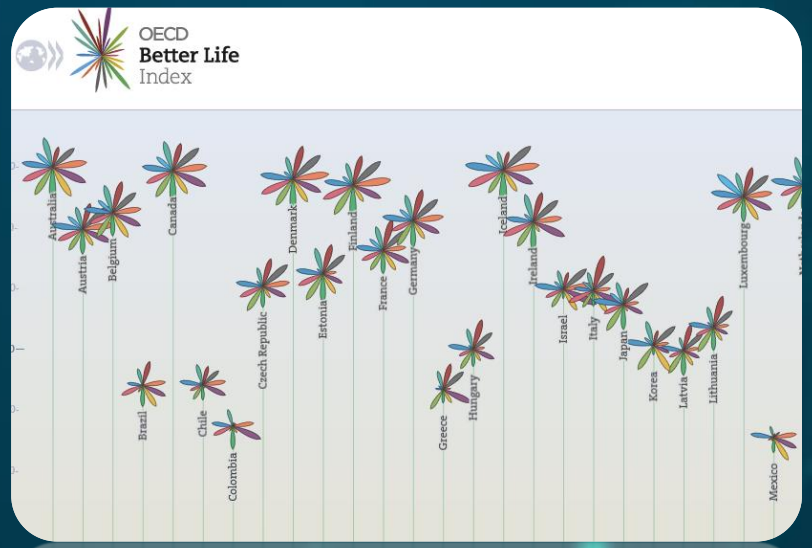

Питання:

- Навчання зі вчителем / без вчителя/ з підкріпленням?
- Задача класифікації / регресії/ кластеризації …?

Отримання даних

```python
import pandas as pd

bli=pd.read_csv('reg/BLI.csv',thousands=',')
bli.head()
```

```python
bli=pd.read_csv('reg/BLI.csv',thousands=',')
bli.head()
```

✓ 0.6s Python

	LOCATION	Country	INDICATOR	Indicator	MEASURE	Measure	INEQUALITY	Inequality	Unit Code	Unit	PowerCode Code	PowerCode	Reference Period Code	Reference Period	Value	Flag Codes	Flags
0	AUS	Australia	JE_LMIS	Labour market insecurity	L	Value	TOT	Total	PC	Percentage	0	Units	NaN	NaN	5.4	NaN	NaN
1	AUT	Austria	JE_LMIS	Labour market insecurity	L	Value	TOT	Total	PC	Percentage	0	Units	NaN	NaN	3.5	NaN	NaN
2	BEL	Belgium	JE_LMIS	Labour market insecurity	L	Value	TOT	Total	PC	Percentage	0	Units	NaN	NaN	3.7	NaN	NaN
3	CAN	Canada	JE_LMIS	Labour market insecurity	L	Value	TOT	Total	PC	Percentage	0	Units	NaN	NaN	6.0	NaN	NaN
4	CZE	Czech Republic	JE_LMIS	Labour market insecurity	L	Value	TOT	Total	PC	Percentage	0	Units	NaN	NaN	3.1	NaN	NaN

```python
bli.info()
```

```
bli.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2369 entries, 0 to 2368
Data columns (total 17 columns):
 #   Column                 Non-Null Count  Dtype
---  ------                 --------------  -----
 0   LOCATION               2369 non-null   object
 1   Country                2369 non-null   object
 2   INDICATOR              2369 non-null   object
 3   Indicator              2369 non-null   object
 4   MEASURE                2369 non-null   object
 5   Measure                2369 non-null   object
 6   INEQUALITY             2369 non-null   object
 7   Inequality             2369 non-null   object
 8   Unit Code              2369 non-null   object
 9   Unit                   2369 non-null   object
 10  PowerCode Code         2369 non-null   int64
 11  PowerCode              2369 non-null   object
 12  Reference Period Code  0 non-null       float64
 13  Reference Period       0 non-null       float64
 14  Value                  2369 non-null   float64
 15  Flag Codes             0 non-null       float64
 16  Flags                  0 non-null       float64
dtypes: float64(5), int64(1), object(11)
memory usage: 314.8+ KB
```

```python
gdp20=pd.read_csv('reg/GDP20.csv',thousands=',',delimiter=';',encoding='latin1',na_values='n/a')
gdp20.head()
gdp20.info()
```

	WEO Country Code	ISO	WEO Subject Code	Subject Descriptor	Subject Notes	Units	Scale	Country/Series-specific Notes	1980	1981	...	2017	2018	2019	GDP per capita	2021	2022	2023
Country																		
Afghanistan	512	AFG	NGDPDPC	Gross domestic product per capita, current prices	GDP is expressed in current U.S. dollars per p...	U.S. dollars	Units	See notes for: Gross domestic product, curren...	NaN	NaN	...	532.220	505.909	507.290	499.441	505.827	523.013	540.522
Albania	914	ALB	NGDPDPC	Gross domestic product per capita, current prices	GDP is expressed in current U.S. dollars per p...	U.S. dollars	Units	See notes for: Gross domestic product, curren...	728.359	817.734	...	4542.760	5284.442	5323.185	4898.277	5160.770	5647.781	6217.287
Algeria	612	DZA	NGDPDPC	Gross domestic product per capita, current prices	GDP is expressed in current U.S. dollars per p...	U.S. dollars	Units	See notes for: Gross domestic product, curren...	2268.607	2305.505	...	4012.134	4080.913	3898.011	3331.076	3449.415	3512.055	3541.217
Angola	614	AGO	NGDPDPC	Gross domestic product per capita, current prices	GDP is expressed in current U.S. dollars per p...	U.S. dollars	Units	See notes for: Gross domestic product, curren...	745.119	679.020	...	4303.693	3620.589	2967.958	2021.310	2129.753	2198.090	2317.595
Antigua and	311	ATG	NGDPDPC	Gross domestic product	GDP is expressed in current	U.S. dollars	Units	See notes for: Gross domestic product,	1920.270	2177.102	...	15655.225	16860.955	17195.459	14158.571	14747.840	16368.891	17756.517

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 195 entries, 0 to 194
Data columns (total 56 columns):
 #   Column                      Non-Null Count  Dtype
---  ------                      --------------  -----
 0   WEO Country Code            195 non-null    int64
 1   ISO                         195 non-null    object
 2   WEO Subject Code            195 non-null    object
 3   Country                     195 non-null    object
 4   Subject Descriptor          195 non-null    object
 5   Subject Notes               195 non-null    object
 6   Units                       195 non-null    object
 7   Scale                       195 non-null    object
 8   Country/Series-specific Notes 194 non-null  object
 9   1980                        138 non-null    float64
 10  1981                        140 non-null    float64
 11  1982                        140 non-null    float64
 12  1983                        140 non-null    float64
 13  1984                        140 non-null    float64
 14  1985                        141 non-null    float64
 15  1986                        142 non-null    float64
 16  1987                        142 non-null    float64
 17  1988                        142 non-null    float64
 18  1989                        142 non-null    float64
 19  1990                        150 non-null    float64
```

Візуалізація та аналіз

```
country_stats.head(20)
```

✓ 0.5s

Country	GDP per capita	Life satisfaction
Brazil	6450.451	6.4
Turkey	7715.373	5.5
Poland	15303.544	6.1
Latvia	17230.136	5.9
Greece	18168.338	5.4
Slovak Republic	18669.295	6.2
Lithuania	19883.066	5.9
Portugal	21608.349	5.4
Czech Republic	22627.469	6.7
Estonia	22985.858	5.7
Slovenia	25038.792	5.9
Spain	26831.629	6.3
Korea	30644.427	5.9
Italy	30657.296	6.0
New Zealand	38675.319	7.3
Japan	39047.860	5.9
United Kingdom	39228.516	6.8
France	39257.434	6.5

```
country_stats.plot(kind='scatter',x='GDP per capita',y='Life satisfaction')
```

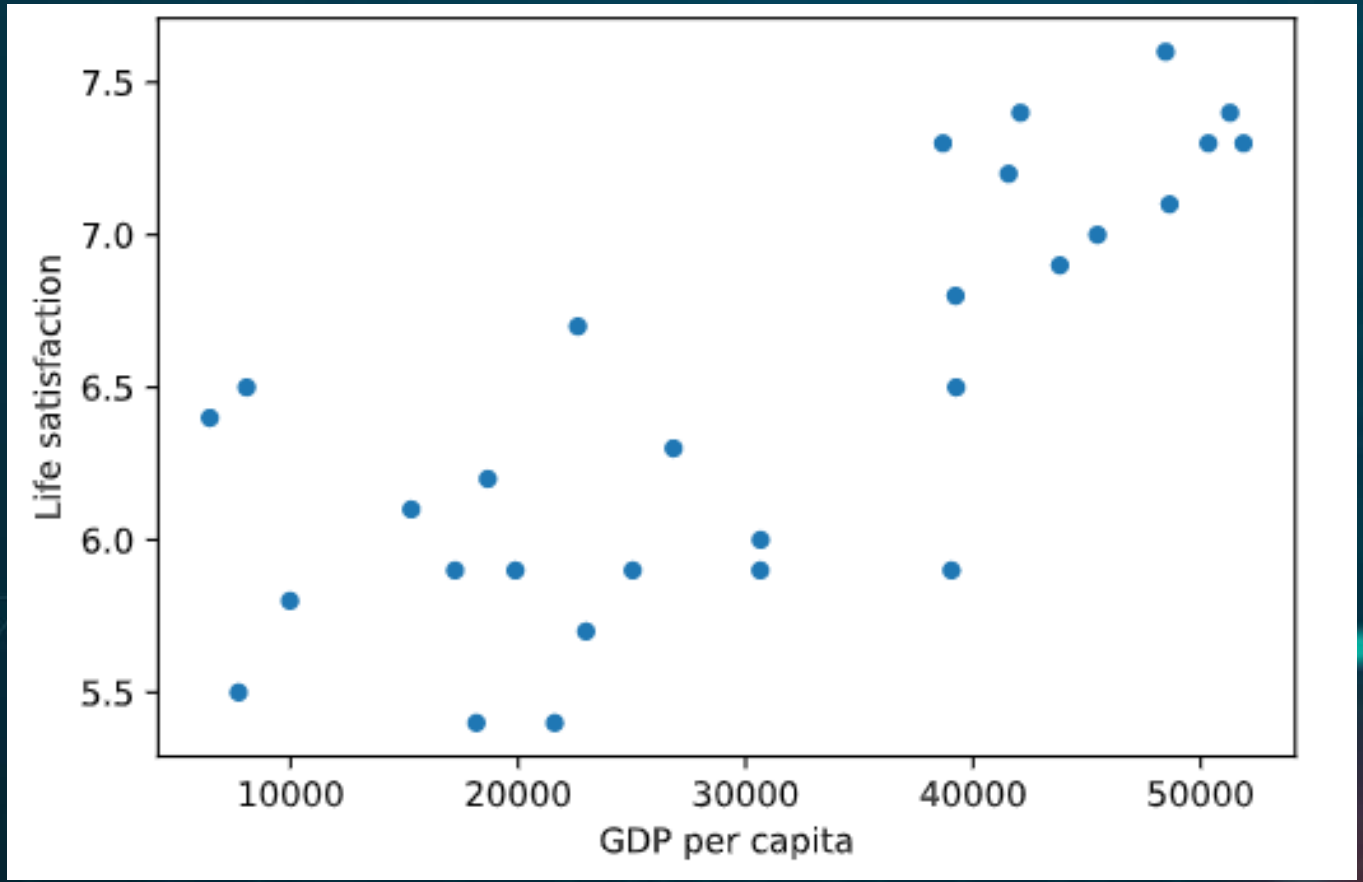

Підготовка даних для алгоритмів МН

```
#prepare training and test sets
from sklearn.model_selection import train_test_split
train_C_set,test_C_set=train_test_split(country_stats,test_
size=0.2,random_state=42)

X_train=numpy.c_[train_C_set['GDP per capita']]
y_train=numpy.c_[train_C_set['Life satisfaction']]
X_test=numpy.c_[test_C_set['GDP per capita']]
y_test=numpy.c_[test_C_set['Life satisfaction']]
```

Навчальна вибірка

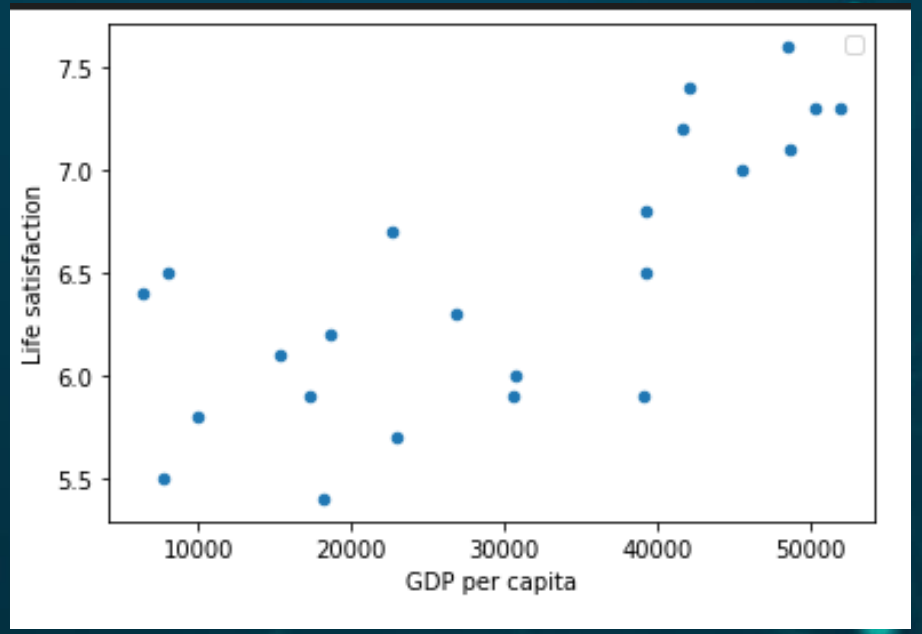

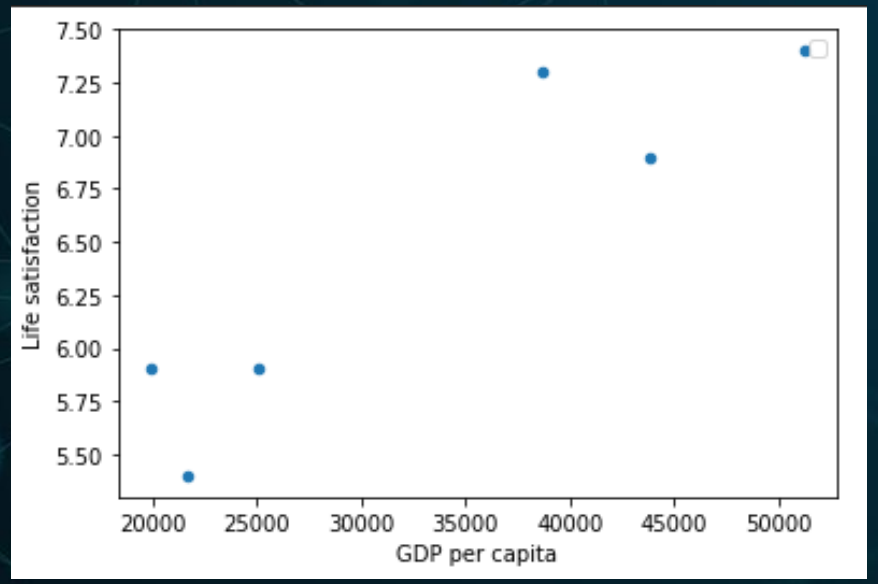

Тестова вибірка

Підготовка даних для алгоритмів МО

1. Очищення даних. В реальних задачах дані можуть містити пропуски. Це може бути викликано тим, що клієнти не заповнювали всі поля в анкеті або акаунті, або тим, що не всі параметри були оцифровані за весь час роботи системи.
Таким чином, постає питання про те, як інтерпретувати пропуски.

Більшість алгоритмів МН не здатні працювати з пропущеними даними.
Можливі способи вирішення:

- Видалити рядки з пропусками;
- Видали такі атрибути (стовбці);
- Встановити пропущене значення (ноль, середнє…)

	WEO Subject Code	Country	Subject De	Subject N	Units	Scale	2002	2003	2004	2005	2006	2007	2008	2009	
2	NGDP_R	Afghanist	Gross don	Expressed	National c	Billions	453.484	492.903	496.209	554.91	584.658	662.65	688.247	829.924	89
3	NGDP_RPCH	Afghanist	Gross don	Annual pe	Percent change		n/a	8.692	0.671	ноя.83	5.361	13.34	3.863	20.585	8.
4	NGDP	Afghanist	Gross don	Expressed	National c	Billions	178.756	220.013	246.21	304.926	345.817	427.495	517.509	607.227	71
5	NGDPD	Afghanist	Gross don	Values are	U.S. dollar	Billions	4.367	4.553	5.146	6.167	6.925	8.556	10.297	12.066	15
6	PPPGDP	Afghanist	Gross don	These dat	Purchasin	Billions	19.661	21.792	22.527	25.982	28.22	32.848	34.772	42.198	46
7	NGDP_D	Afghanist	Gross don	The GDP c	Index		39.418	44.636	49.618	54.951	59.149	64.513	75.192	73.167	79
8	NGDPRPC	Afghanist	Gross don	GDP is exp	National c	Units	24,240.97	25,307.04	24,519.48	26,491.22	27,072.44	29,547.74	29,927.65	35,172.94	37
9	NGDPRPPPC	Afghanist	Gross don	GDP is exp	Purchasin	Units	1,442.77	1,506.22	1,459.35	1,576.70	1,611.29	1,758.62	1,781.23	2,093.42	2,
10	NGDPPC	Afghanist	Gross don	GDP is exp	National c	Units	9,555.40	11,296.10	12,166.14	14,557.09	16,012.96	19,062.11	22,503.29	25,734.84	29
11	NGDPDPC	Afghanist	Gross don	GDP is exp	U.S. dollar	Units	233.433	233.755	254.259	294.396	320.674	381.502	447.746	511.374	63
12	PPPPC	Afghanist	Gross don	Expressed	Purchasin	Units	1,050.99	1,118.87	1,113.15	1,240.38	1,306.71	1,464.72	1,512.00	1,788.40	1,
13	NGAP_NPGDP	Afghanist	Output ga	Output ga	Percent of potential GDP										
14	PPPSH	Afghanist	Gross don	Expressed	Percent		0.036	0.037	0.036	0.038	0.038	0.041	0.041	0.05	0.
15	PPPEX	Afghanist	Implied P	Expressed	National currency pe		9.092	10.096	10.929	11.736	12.254	13.014	14.883	14.39	15
16	NID_NGDP	Afghanist	Total inve	Expressed	Percent of GDP		27.243	30.102	35.354	37.048	29.489	55.852	30.222	36.503	30
17	NGSD_NGDP	Afghanist	Gross nati	Expressed	Percent of GDP		61.151	59.718	72.57	67.274	50.333	119.243	63.99	78.09	59
18	PCPI	Afghanist	Inflation,	Expressed	Index		31.263	42.413	49.351	54.566	58.269	63.327	80.057	74.604	76
19	PCPIPCH	Afghanist	Inflation,	Annual pe	Percent change		n/a	35.663	16.358	10.569	6.785	8.681	26.419	-6.811	2.
20	PCPIE	Afghanist	Inflation,	Expressed	Index		42.89	45.691	51.752	57.219	59.671	69.273	82.306	74.211	81
21	PCPIEPCH	Afghanist	Inflation,	Annual pe	Percent change		n/a	июн.53	13.266	10.562	4.285	16.092	18.814	-9.836	10
22	FLIBOR6	Afghanist	Six-month	London ir	Percent										
23	TM_RPCH	Afghanist	Volume o	Percent ch	Percent change		n/a	36.077	-1.088	54.659	-2.541	-9.417	-8.876	30.203	32

WEOOct2021all(1)

Обробка текстових і категоріальних атрибутів

	X	Y	month	day	FFMC	DMC	DC	ISI	temp	RH	wind	rain
306	7	4	sep	sun	89.6	84.1	714.3	5.7	17.1	53	5.4	0.0
358	6	3	sep	fri	92.5	122.0	789.7	10.2	19.7	39	2.7	0.0
43	4	4	sep	sat	92.5	88.0	698.6	7.1	19.6	48	2.7	0.0
235	8	6	aug	sun	91.4	142.4	601.4	10.6	19.6	41	5.8	0.0
188	6	4	mar	sat	90.8	41.9	89.4	7.9	13.3	42	0.9	0.0

На прикладі показано 2 категоріальних атрибути, що мають обмежену кількість значень:
month: sep, oct…
day: sun, mon, tue…

Вибір моделі та її налаштування

Проста регресійна модель для оцінки задоволеності рівнем життя являє собою лінійну функцію від вхідної ознаки ВВП_на_душу_населення

$$life_sut = \theta_0 + \theta_1 * GPD$$

Прогнозом лінійної моделі є зважена сума вхідних ознак з додаванням зміщення:

$$\hat{y} = \theta_0 + \theta_1 * x_1 + \cdots + \theta_n * x_n$$

$\hat{y}$ - прогнозоване значення;
n – кількість ознак;
x_i - значення i-ї ознаки;
θ_i - i-й параметр моделі

У якості міри ефективності використовуватиметься середньоквадратична помилка Mean Square Error - MSE:

$$MSE(\theta) = \frac{1}{m}\sum_{i=1}^{m}\left(\boldsymbol{\theta}^T \boldsymbol{x}^{(i)} - y^{(i)}\right)^2$$

Вибір моделі та її налаштування

```
import matplotlib.pyplot as plt
import sklearn.linear_model
model=sklearn.linear_model.LinearRegression()
model.fit(X_train,y_train)
```

```
country_stats.plot(kind='scatter',x='GDP per capita',y='Life
 satisfaction')
plt.plot(X_train,model.predict(X_train),'r-
+',linewidth=2,label='pred')
plt.legend()
```

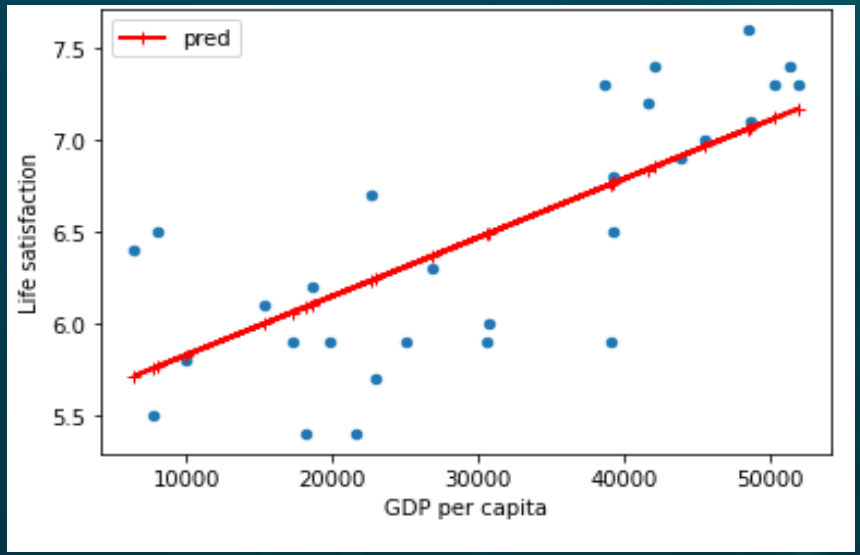


```
test_C_set.plot(kind='scatter',x='GDP per capita',y='Life sa
tisfaction')
plt.plot(X_test,model.predict(X_test),'y-
+',linewidth=2,label='pred')
plt.legend()
```

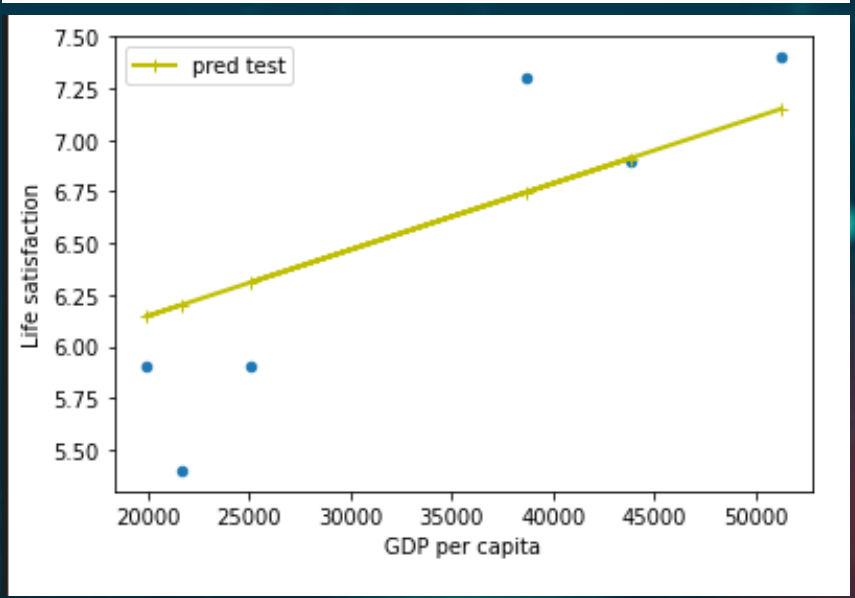

Метрика, яка використовується для оцінки ефективності моделі – R^2 score, що визначається як:

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2}, \quad \bar{y} = \frac{1}{N}\sum_{i=1}^{N} y_i$$

де $\hat{y}_i$ – спрогнозоване значення для і-го прикладу, y_i- реальне значення для і-го прикладу.
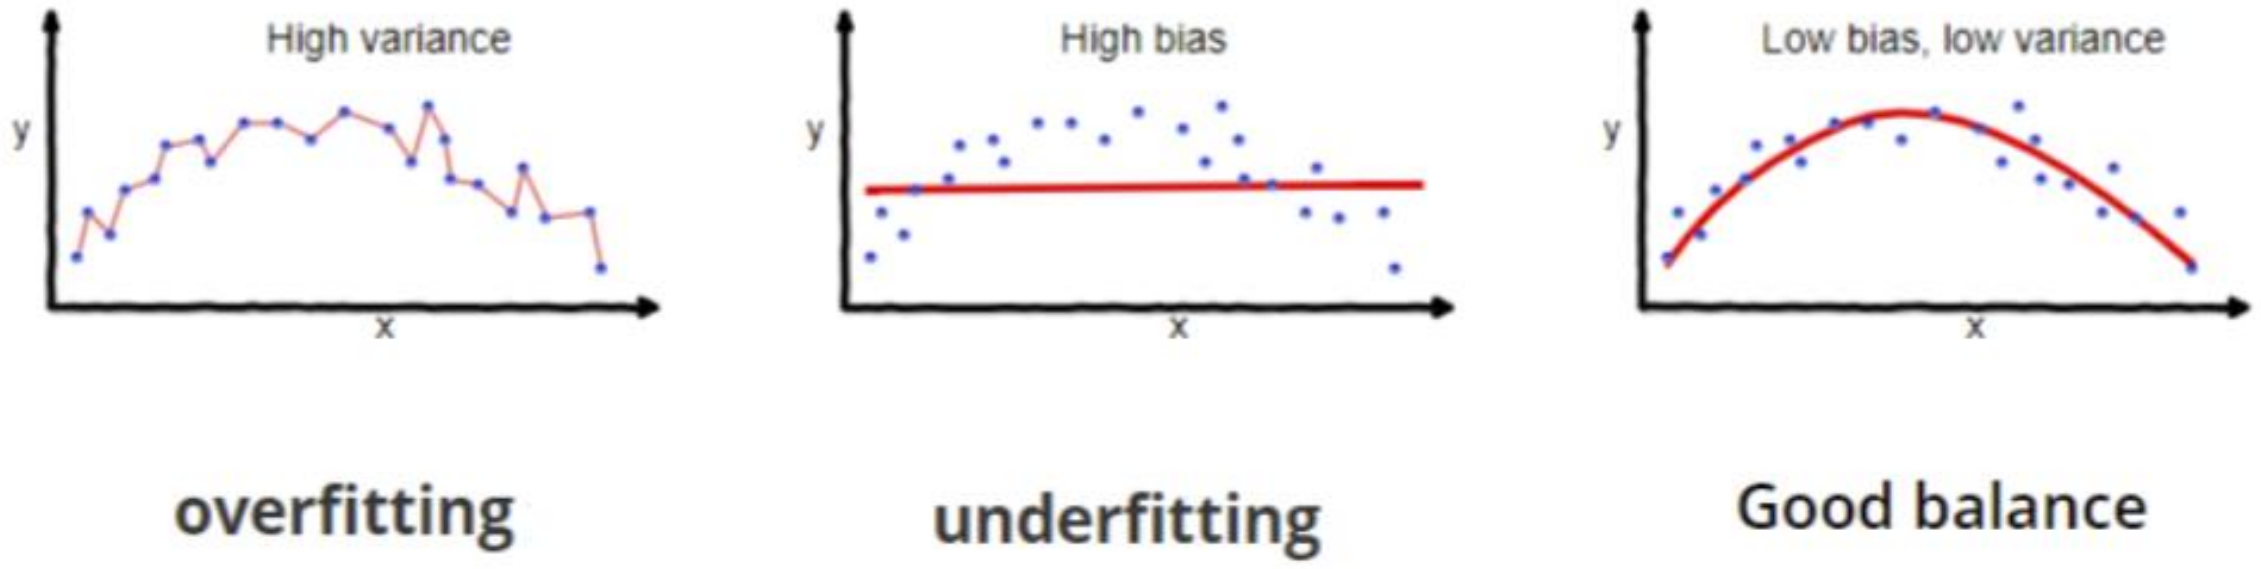
Якість навчання